分类号_____ 学号 M201772462

学校代码 10487 密级 公开

華中科技大學

硕士学位论文

基于深度学习的红外图像仿真和红外图像超分辨率重建

学位申请人： 瞿鑫

学 科 专 业：控制科学与工程

指 导 教 师： 王岳环 教授

答 辩 日 期： 2020 年 6 月

中国知网 https://www.cnki.net

A Thesis Submitted in Partial Fulfillment of the Requirements for the Degree of Master of Engineering

Infrared image simulation and infrared image super-resolution reconstruction based on deep learning

Candidate : **Qu Xin**

Major : **Control Science and Engineering**

Supervisor : **Prof. Wang Yuehuan**

Huazhong University of Science & Technology
Wuhan 430074, P.R.China
June, 2020

中国知网 https://www.cnki.net

中国知网 https://www.cnki.net

摘 要

红外成像技术在军事领域具有极大的应用研究价值，长期以来各国都在获取红外图像上投入了大量的精力。通过计算机进行红外图像的仿真工作，具有节省人力、物力、财力等诸多优势。传统计算机仿真生成红外图像的方法，过程繁琐，生成大规模红外图像较为困难。近年来不少研究者将机器学习、深度学习的相关方法与思想引入到红外图像仿真生成中。论文利用深度学习方法，将较容易获取到的可见光图像，转换为相应的红外图像,为后续的红外图像检测识别任务提供数据支持。为了能在较高分辨率的红外成像条件下进行目标的检测识别任务，论文利用深度学习方法，对仿真生成的部分低分辨率红外图像进行超分辨率重建，得到分辨率更高的红外图像，提升红外图像中目标检测识别效果。

论文以 CycleGAN 模型为基本网络结构，进行红外图像的仿真工作。针对红外图像在仿真生成过程中容易出现过拟合，导致生成的部分红外图像中出现图像整体质量差、局部错误映射等问题，提出在生成器网络与判别器网络结构之间，增加抑制器结构，抑制图像在生成过程中的过度变化，减少生成过程的过拟合现象。针对 CycleGAN 网络中一条路径生成的结果可能和另一条路径重建的结果存在差别的情况，提出在两条训练路径之间增加计算通路损失的损失函数，将一条路径生成器生成的结果与另一个路径循环重建的结果进行比较，减少非相关信息的添加。针对原始 CycleGAN 网络在进行卷积操作过程中，对图像的细粒度特征关注不够，论文引入注意力模块（CBAM），加强仿真生成红外图像过程中对细节特征的刻画。

在实际工程应用中，由于此前红外成像器获得的红外图像分辨率较低，用该红外图像数据作为训练样本，仿真生成的部分红外图像中也存在分辨率低、图像质量低等问题。为了能在较高分辨率的红外成像条件下进行红外图像目标检测识别任务，论文以 SRGAN 模型为基本网络，对改进 CycleGAN 网络仿真生成的红外图像进行超分辨率重建工作，提升红外图像的分辨率。为了更大限度保留图像的底层信息，同时防止网络出现梯度弥散以及梯度爆炸等情况，借鉴 DenseNet 思想，对原始

中国知网 https://www.cnki.net

SRGAN 的生成器网络结构改进，使用密集链接方式，增加整个网络对底层信息的感知。针对红外图像中边缘、纹理信息的重要性，提出在 SRGAN 网络的损失函数中加入计算边缘梯度损失项的损失函数，使生成器能充分学习到红外图像的边缘信息，从而超分重建出几何边缘清晰、突出的红外图像。

关键词： 生成对抗网络　红外图像仿真　抑制器结构　超分辨率重建　密集连接

中国知网 https://www.cnki.net

Abstract

Infrared imaging technology has many research values in many field, so many countries invest a lot in acquiring infrared data. The way of generating infrared scene by computer simulation has many advantages such as saving manpower, material resources, and financial resources. However, the traditional way of infrared-scene simulation by computer, needs a lot of physical calculation, and it is difficult to generate large-scale infrared scene by this way. In recent years, many researchers introduce machine learning and deep learning methods into the field of infrared scene generation. This paper uses the deep learning methods to convert the visible light images into the infrared images. And this infrared images will provide data support for the infrared images detection and recognition tasks. In order to carry out infrared target detection and recognition tasks under higher resolution imaging conditions, this paper decides to use the deep learning methods to super-resolution reconstruction of the low-resolution infrared images to get the infrared images with richer information and higher resolution.

This paper uses the CycleGAN model as the basic network structure to generate infrared images. For the case that it is easy to occur over-fitting in the process of generating infrared images, which will lead to problems such as poor overall image quality and local error mapping in some generated infrared images. This paper proposes to add suppressor network structure between the generator network and the discriminator network. For the case that the result generated by one path in CycleGAN network may be different from the result reconstructed by another path. This paper proposes to add a loss function to calculate the path loss between the two training paths. By this way, the network can compare the result of the generator with the result of another path loop reconstruction. For the case that the original CycleGAN focus on the fine-grained features of image is not enough during the convolution operation, this paper propose to introduce

中国知网 https://www.cnki.net

the attention module (CBAM) into the network, to enhance the description of details in the generating process.

In practical engineering applications, the infrared images obtained by traditional infrared imagers are low resolution and poor quality. Using these data as the training samples, may generate the infrared images with low resolution and low image quality. In order to perform infrared target detection and recognition tasks under higher resolution imaging conditions, this paper use the SRGAN model as the basic network to perform super-resolution reconstruction of the infrared scene. In order to retain the underlying information of the image, and prevent gradient dispersion and gradient explosion of the network, this paper use dense links to increase the entire network's perception of the underlying information. For the case that the edge and texture information is very important in infrared images, this proposes to add a loss function to calculate the edge gradient loss term into the loss function of the SRGAN network. By this way, the generator can fully learn the edge information of the infrared image, and gets the infrared images with clear and prominent geometric edges and reconstructed textures.

Key words: Generative adversarial network Infrared-scene simulation Suppressor structure Super-resolution reconstruction Dense connection

中国知网 https://www.cnki.net

目 录

摘 要 ····· **I**

ABSTRACT ····· **III**

1 绪论 ····· **1**

1.1 研究背景和意义 ····· 1

1.2 国内外研究概况 ····· 2

1.3 本文主要研究工作 ····· 10

2 基本原理 ····· **13**

2.1 生成对抗网络原理 ····· 13

2.2 CYCLEGAN 网络原理 ····· 15

2.3 SRGAN 网络原理 ····· 18

2.4 评价指标 ····· 19

2.5 本章小结 ····· 20

3 基于改进循环生成对抗网络的红外图像仿真 ····· **22**

3.1 循环生成对抗网络 ····· 22

3.2 循环生成对抗网络改进 ····· 27

3.3 实验结果与分析 ····· 34

3.4 本章小结 ····· 45

4 基于改进 SRGAN 网络的红外图像超分辨率重建 ····· **47**

4.1 SRGAN 网络 ····· 47

4.2 SRGAN 网络改进 ····· 51

4.3 实验结果与分析 ····· 56

4.4 本章小结 ····· 67

5 总结与展望 ····· **68**

5.1 论文工作总结 ····· 68

5.2 课题研究展望 ····· 69

致谢 ····· **71**

参考文献 ····· **71**

中国知网 https://www.cnki.net

附录 1　攻读学位期间取得的成果…… 77

中国知网　https://www.cnki.net

1 绪论

1.1 研究背景和意义

可见光图像指的是人眼可见波段范围内光线所成的图像，可见光成像具有成像技术成熟、可视化效果好等特点，在日常生活中具有广泛的应用。红外图像指的是红外波段所成的图像，反映图像的红外特性。红外波段的成像技术，由于具有探测能力强以及抗干扰能力强等特点，在武器制导、目标检测、跟踪等领域都有着极其广泛的应用。因此红外图像数据的获取受到了极大的重视，各国都在红外图像获取领域上加大了研究力度与资金投入。

红外图像获取目前主要通过红外相机进行实时拍摄，以及通过计算机技术仿真生成。通过计算机仿真技术仿真生成红外图像的方法由于具有可以节省大量物力、人力、财力等优势，受到极大的重视，特别是近年来不仅计算机软硬件技术得到的飞速的发展、红外仿真的理论也有了很大程度的完善，使得利用计算机仿真生成真实感较高的红外图像成为了可能。此外随着近年来深度学习技术理论与应用的发展，将深度学习方法应用到图像生成领域成为研究热点之一。该技术具有通过模型训练能快速、大规模生成真实感较强、质量较高的图像等优势，因此越来越多的研究人员与单位加入到了应用深度学习技术进行图像生成工作中。鉴于红外图像数据资源较为匮乏，可见光图像数据较为丰富且易于获得，研究者提出了很多方法将可见光图像转换为红外图像。而通过生成对抗网络的图像非对称信息生成方法，可以在一定条件下，将可见光图像转换为相应的红外图像，从而对红外图像数据进行扩充。

然而不管是本文方法仿真的红外图像还是实际拍摄的红外图像，通常存在图像质量不高、分辨率低等问题。为了能在较高分辨率的成像条件下，进行红外目标的检测识别任务，决定对红外图像进行超分辨率重建的工作，可以显著提升红外图像质量，具有极强的应用价值与研究意义。近年来应用深度学习的理论和方法对图像、视频等进行超分辨率重建处理，受到广大研究者和机构的关注，在军事领域应用超分辨率重建方法对红外、雷达、声呐图像进行处理，也是目前研究方向之一。本文

中国知网 https://www.cnki.net

应用深度学习模型对低质量、低分辨率红外图像进行超分辨率重建工作，可以得到质量高、分辨率高、信息丰富的红外图像，为军事目标检测与跟踪等领域提供更好的数据服务，提升军事领域目标的跟踪、检测能力。

基于以上讨论可见，利用深度学习方法进行红外图像生成，以及对红外图像进行超分辨率重建，都具有很强的应用价值和研究意义。

1.2 国内外研究概况

1.2.1 基于物理模型的红外图像仿真研究概况

红外图像主要反应物体的红外特性，相关的红外图像生成工作在军事领域具有极为重要的作用。传统生成红外图像的方法，首先要获得图像的温度特性，温度特性能够反映红外图像的红外分布，再通过分析不同材质的热传导模型进行红外纹理生成，最后输出得到的红外图像。美国军方相关研究机构在 20 世纪 50 年代就开始研究军用目标的红外特性。Dozier 等人[1]研究了太阳照射下下地形红外特性参数的快速算法，大大简化了地形红外情况的计算。Jacobs 等人[2][3]构建一维热传导模型，他们通过一维热模型计算出物体表面温度分布情况，建立了计算简单几何外形表面的温度场分布情况，并首次对公路以及砖墙等一些具有简单几何外形的目标进行红外仿真。Dobbs 和 Biesel 等人[4]通过建立数学模型来求解目标的红外情况，他们利用数学函数来拟合出目标物体表面的温度场分布情况。Cathcat 等人[5]建立不同条件下物体的红外成像仿真模型 PRISM，在这个模型中同时考虑到了物体表面的材质、物理结构和大气因素，同时在模型构建中也结合了初始条件和边界条件。BenYosef 等人[6]构建了一个自然地形中一天中日变化的红外模型，初步实现对一天中场景在不同时刻下的红外情况模拟。

近年来随着计算机技术的不断发展，国外研究并开发了很多专门用于红外仿真的软件。北约各国经过多年的研发工作，开发了 NIRATAM[7]用于对空中目标进行红外仿真，该软件可以计算飞机以及反导武器等军用目标的红外情况。而美国 Multi-Gen 公司则开发出 SeneorVision 红外仿真模块，Quanturn3D 公司开发出 viXsen 红外仿真

中国知网 https://www.cnki.net

模块，并且这些红外仿真模块，在各种红外视景仿真软件中也都得到了很好的应用，例如英国 INSYS 公司开发的 CameoSim 软件用于红外场景仿真领域，美国的 Multi-Gen 公司集成 SeneorVision 红外仿真模块，研究出了 Vega 红外仿真软件，法国 OKTAL-SE 研究机构则开发出了交互性较好的 SE-Workbench[8]红外场景仿真软件。

国内学者在红外仿真领域虽然起步较晚，但仍然克服众多困难开展自主研究道路，并且取得不错的成果。徐南荣[9]分析计算出了飞机不同部位蒙皮的红外情况，同时他还对飞机尾焰以及飞机喷管处的红外情况进行了计算。周强[10]等人试图建立可见光图像和红外图像间的映射关系，他们通过相机标定和对物体材质分割的方法，同时结合自己采集到的近红外波段内物体的光谱反射率情况，初步建立了红外图像与可见光图像间映射关系，之后他又结合此映射关系，利用查表和材质分割的方法，将可见光图像转换为红外图像。王章野等[11]利用虚拟现实技术，从信息融合的角度出发，完成了对地面的红外仿真。

国内的一些高校和科研院所也展开了对目前国际上较为成熟的红外仿真软件进行二次开发的研究工作。颜轶[12]通过对 MultiGen Creator、Vega 红外仿真软件的二次开发研究，成功实现了舰船、坦克、飞机的红外特性仿真研究工作。张云[13]等人在 SE-Workbench 软件平台上实现了对背景红外特性探究工作。张天序等人[14]利用对 Vega 软件的二次开发，实现了从多角度对海面舰船的多视点红外特性仿真工作。利用国际上较为成熟的红外仿真软件，并对其进行二次开发，能够生成真实性和可用性较高的红外图像。但是由于红外图像多用于军事领域，这些红外仿真软件，包括其中的部分关键模块，不仅购买价格高昂，而且很多都是不面向我国出售的。此外应用此类红外仿真软件，通常需要进行场景的三维建模、对场景进行分割，之后再对场景不同区域、不同材质赋温度值、材质属性，同时需要建立大气传输模型，最后需要应用计算机图形学方法进行红外场景渲染工作。这种方法虽然可以获得真实感很好的红外图像，但是这种方法的研究成本较高，而且针对不同场景都需要不同处理，适应能力不高，研发周期长，对于大规模、多种类的红外图像仿真工作难度较高。

中国知网 https://www.cnki.net

1.2.2 基于学习方法的可见光图像生成研究概况

随着近年来基于学习方法的迅猛发展，很多研究者也把深度学习、机器学习技术应用到包括红外图像在内的诸多图像生成领域。Hertzmann[15]等人提出通过一个输入输出图像对，训练出了一个非参数自回归的纹理生成模型结构的类比计算方法，但是该方法只能进行简单图像的生成工作，并且可操作性不强。随着深度学习技术的发展，可以使用带有参数的模型来解决转换问题，卷积神经网络由于其模型结构自身就带有大量参数，因此其在图像生成的应用上得到飞速发展。Gatys 等[16][17]提出了使用神经网络的图像生成方法，他们提出了一种将风格与内容分离的算法，并且利用图像在 VGG-19 网络中的特征空间计算 Gram Matrix，并将其作为图像风格的统计特征描述，然后再通过 VGG-19 对图像的内容特征计算，把输入的图像通过误差的反向传播过程进行计算，约束输入图像的内容特征和目标图像保持一致。而 Johnson 等人[18]在此基础上，提出了使用相同的目标函数，训练出一个前馈神经网络模型结构，每次产生风格图像只需要将源图像通过一次前馈网络即可，大大加速了 Gatys 的网络模型。基于监督学习的图像生成，虽然具有较好的效果，但是需要大量网格标签数据。基于无监督学习的深度学习模型（例如生成对抗网络），进行图像生成工作，可以在训练数据集成对或不成对的情况下，让网络模型结构学习输入图像与输出图像间的映射关系。

生成对抗式网络（GAN）在 2014 年由 Goodfellow[19]等人提出，最初 GAN 网络的生成器网络结构接受一个噪声向量作为输入，然后再通过生成器网络生成一张图像，而判别器网络结构是一个分类器的模型结构，用来对生成数据和真实数据进行判别工作，相互博弈生成真实数据。Mirza[20]等人针对原始 GAN 对于生成器几乎没有任何约束，提出在原始 GAN 的基础上，通过向生成器增加约束条件，使网络朝着既定的方向生成样本，控制了 GAN 过于自由的问题。Denton E 等人[21]提出了 LAPGAN 结构，该方法在 GAN 网络中引入了拉普拉斯金字塔以及高斯金字塔，分别用于超分辨率重建中图像的上采样、下采样操作。Zhu W 等人[22]提出 DCGAN 网络结构，在 GAN 中使用一系列的训练技巧，如使用批归一化稳定训练，同时使用

中国知网 https://www.cnki.net

ReLU 激活函数降低梯度风险，并且取消了池化层，对 GAN 的发展有着极大的推动作用。

Arjovsky M 等人[23]提出利用 Wasserstein 距离代替 JS 距离，对真实样本与生成样本间的距离进行度量的 WGAN 模型，并且通过使用 weight clipping 方法将参数 clip 到$[-c,c]$范围内，用来改善 GAN 网络训练过程中的稳定性。Phillip Isola 等人[24]提出 pix2pix 网络结构，利用配对数据集，可以对不同域图像进行转换，并得到较高质量的转换结果，但是该方法要求训练集必须是严格一一配对的。传统方法进行两个不同域中的图片之间的相互转换，一般需要两个域中具有相同内容的成对图片作为训练数据，但是这种成对的训练数据往往很难获得。Zhu Y J 等人[25]提出具有环形网络结构的 CycleGAN 网络，该结构具有循环机制，实现两个域转换和约束，可以让两个域的图片相互转化并且不需要严格配对的图片作为训练数据。随着深度学习网络规模的不断加大，生成图像质量的也越来越高，Brock A 等人[26]提出 BigGAN 网络结构，该结构在 ImageNet 训练下，IS 高达 166.3。次年 Jeff Donahue 等人[27]在 BigGAN 基础上提出 BigBiGAN 网络结构，这两种网络结构通过扩大模型规模，在训练过程中使用很大的 Batch，并且在卷积层的设计上使用了更大的通道数，能对生成的图像质量得到很大程度的提升，但是这两种网络结构参数量极大，训练极为困难，庞大的参数需要 TPU 这样的硬件进行训练且成本极高。

1.2.3 基于学习方法的红外图像仿真研究概况

虽然国外目前主要集中在应用深度学习、机器学习方法进行可见光图像领域的生成的研究工作上，但是其中一些方法和理论，经过一定的改进、迁移后，也能用于红外图像的仿真工作中。

部分国内研究者近年来也将机器学习深度学习方法应用到红外图像仿真中。许洪[28]则提出利用 K 均值聚类的方法，对 Fort Carson 图像数据库进行处理，通过聚类的结果对不同目标分割，然后对分割的物体结合光谱数据库（ASTER）中材质发射率情况，对分割的结果进行赋值；黄超超[29]把机器学习方法应用到红外图像仿真领域，他们分析太阳对温度场模型很多参数都会带来影响，因此他将太阳红外特性

中国知网 https://www.cnki.net

参数作为机器学习的输入变量。然后确定温度场模型的参数，减少输入变量的温度，之后使用汽车参数变量，计算汽车的温度场分布，最后在 OpenGL 下实现对汽车目标在运动场景状况下的红外特性研究。邹腊梅等[30]提出将机器学习的分类方法应用到大尺度可见光图像上，他考虑到利用 Vega 进行大尺度高分辨率红外图像仿真时，需要进行大量的材质纹理分割，这会严重降低实时生成大尺度红外图像的能力，他提出利用机器学习对图像分类，之后再进行材质映射，这也可以大大简化大尺度红外图像仿真的步骤。吴晓迪[31]针对直接使用热力学方法，对物体温度场进行建模，计算量较大，提出将 BP 机器学习方法应用到红外图像仿真中，他通过对水泥路面表面温度进行实际测量，获取到温度样本作为训练集，然后再利用 BP 网络建立了路面的温度场模型，并且他还继续延伸，对路面在不同气象条件下的红外情况进行了仿真研究。谢江荣[32]等提出基于生成对抗网络的红外目标仿真方法，他提出使用 DCGAN 网络进行空中红外飞机的生成，并在 DCGAN 网络中加入控制条件，用来控制生成红外飞机目标的方向。

综合以上考虑，使用传统基于物理模型的红外图像仿真方法，工程量极大，在仿真生成红外图像过程中需要考虑很多因素，需要计算的物理模型也较为复杂，且往往只能对特性目标进行仿真。使用国际上较为成熟的红外仿真软件，对其进行二次开发，实现红外图像的仿真过程，由于目前这些软件，包括其中很多关键模块是对国内禁售的，而且这些红外软件进行大规模图像开发，工作量极大。利用基于学习的方法进行红外图像仿真工作，可以通过网络参数学习可见光图像和红外图像间复杂的映射关系，不需要人为考虑过多因素。

1.2.4 基于传统方法的图像超分辨率重建研究概况

工程中，仿真生成的红外图像以及实拍的红外图像可能存在质量不高、分辨率低、包含的红外图像信息不够丰富等问题，为了能在更较高分辨率、成像质量较好红外成像条件下，进行红外目标的检测工作，本文又研究了使用深度学习方法对仿真的红外图像进行超分辨率重建工作。

图像超分辨率重建技术发展至今，国内外学者展开了广泛而深入的研究。大

中国知网 https://www.cnki.net

体上超分辨率重建算法可以按照图 1-1 所示进行分类。

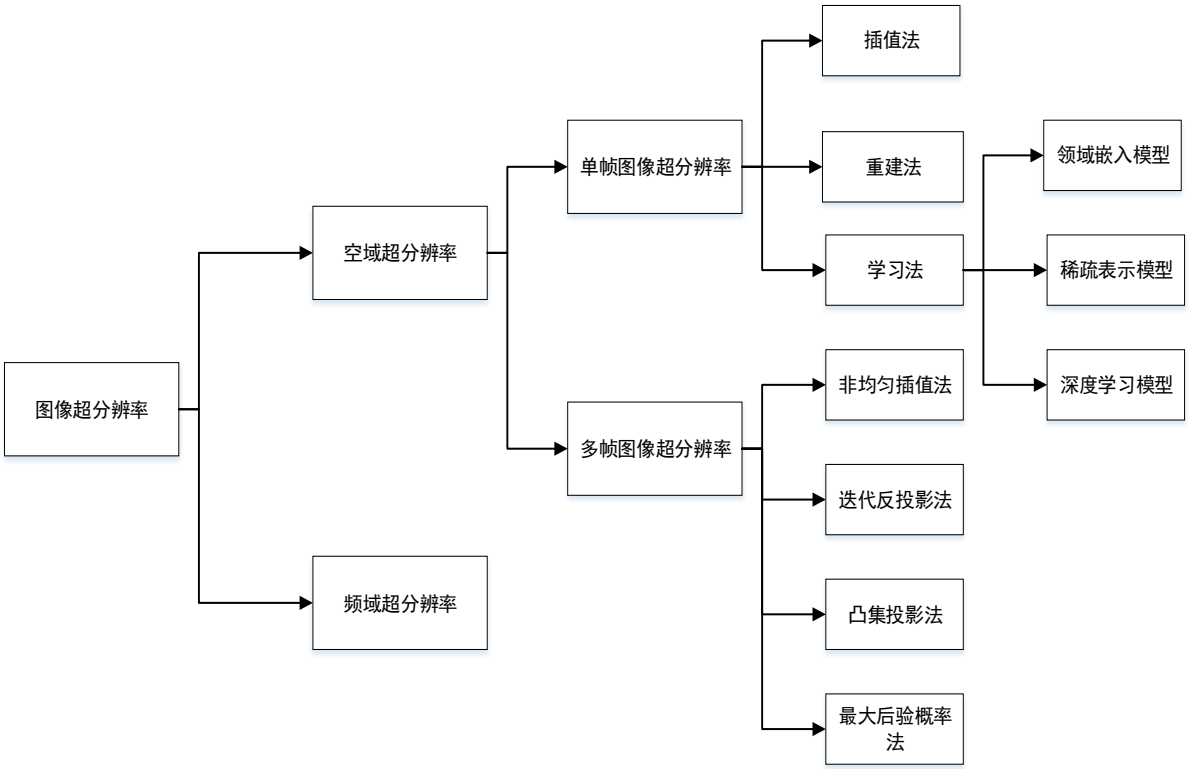

图 1-1　图像超分辨率重建的方法

人们最早是从对单幅图像进行超分辨率重建来开展研究工作的。Harris[33]在上世纪 60 年代，通过在单幅衍射图像中，将带限信号外推，首次完成了超分辨率重建的工作。但这种超分辨率重建方法的缺点是单幅输入图像可获取信息较少，重建效果并不理想。Tsai 和 Huang[34]等人在对多帧遥感卫星图像进行超分重建处理时，首次提出了使用傅里叶变换把多帧 LR 图像通过傅里叶变换，变换到频域中，然后再利用傅里叶变换的移位性质，把图像间的混叠信息进行融合，重构出 HR 图像。Rhee 和 Kang[35]等人在进行单幅图像超分辨率时，发现内存需求和计算负担都比较大，他们提出使用离散余弦变换替换傅里叶变换。Kim[36][37]等人将 Tsai 的方法扩展到有噪声和模糊的情况。

但是在频域对图像进行超分辨率重建，只能对存在全局平移运动的图像进行处理，而对于那些局部运动或者更复杂运动的低分辨率图像难以进行超分辨率重建工作，这些不足使得人们渐渐放弃了这类方法。而在空间域上对多帧图像进行超分辨

中国知网 https://www.cnki.net

率重建处理，逐渐受到了更多的关注。其中 Ur H 与 Gross[38]提出的，使用非均匀插值法进行超分辨率重建工作，基于非均匀插值的方法具有适合实时应用，插值计算量小的优点。Shah 等人[39]提出 Landweber 迭代法对彩色视频序列进行超分辨率重建。但是这种方法要求待处理图像必须是具有相同噪声和模糊的条件。而 Stark 等人[40]把凸集投影法引入到超分辨率重建工作中。而 Alam[41]等人提出首先通过图像配准方法估计图像间的位移参数，然后使用加权最近邻插值法，对经过配准后的图像进行非均匀插值，最后再使用维纳滤波对非均匀插值后的图像进行去噪、去模糊操作。

Irani 和 Peleg[42]在超分辨率重建中引入了迭代投影的方法。这种方法首先初始化一个高分辨率图像（HR），接着对其退化得到低分辨率图像（LR），然后计算实际低分辨率图像和退化得到的低分辨率图像（LR）间的差值，并将这个差值反向投影来修正和估计的图像，反复迭代直到最后收敛。基于多帧的超分辨率重建方法虽然相对较为成熟，然而在许多实际应用中，尤其是在有效低分辨率图像数量不足、大退化、运动估计不准确等情况下，该方法的性能反而会大幅的下降。传统方法进行超分辨率重建中，以对多帧图像的处理为主，这种方法也相对较多。

但是在日常工程中，我们很多时候也需要对单帧图像进行处理。目前对单帧图像进行超分辨率重建主要有三种方法：基于重建、插值、学习的方法[43]。基于差值的超分辨率重建在计算高分辨率图像中的未知像素信息时，使用固定或自适应的滤波内核来进行计算，之后只通过插值算法来进行离散插值，来放大图像。这种方法虽然理论比较简单，但是在实际使用中由于无法恢复图像采集过程中丢失的高频信息，容易导致超分辨率重建的结果边缘过于平滑。而基于重建的方法，在超分辨率重建过程中，由于存在图像退化处理过程，而在这个过程中通常会出现大量的高频信息丢失的情况。该方法在重建中额外引入某些图像验证信息，强化了对整个成像过程的约束，基于重建的方法通常包括保真项和正则项两个数学模型。尽管基于重建的方法对超分辨率重建效果有一定提升，但是这类方法在重建过程中对细节仍然刻画不足，不适合复杂的超分辨应用。

中国知网 https://www.cnki.net

1.2.5 基于学习方法的图像超分辨率重建研究概况

近年来很多高校、研究机构或者个人，从学习角度对超分辨率重建进行研究。这种方法的思想是，通过学习训练数据集中 LR 图像和对应 HR 图像间的映射关系，从而预测出输入的 LR 图像中丢失的高频信息，从而实现图像的超分辨率重建过程，将低分辨率图像转换为相应的高分辨率图像。最早提出利用学习的方法进行超分辨率重建的是 Freeman 等人[44]，他们在低分辨率图像和高分辨率图像之间，使用马尔科夫模型建立起对应关系，然后利用置信传播的方式，对低分辨率图像使用最大后验概率估计得到超分辨率重建的结果。Elad 等人[45]基于图像的稀疏特性，首先提出由局部到总体的重建思想，并将稀疏表示模型用于去噪领域。 Chang 等人[46]提出了使用邻域嵌入的方法进行图像超分，这种方法借鉴了流行学习中的局部线性映射的思想。

深度学习方法可以使得超分辨率重建的效果，得到了很大程度的提升。董超等人[47]在基于样本学习的 SR 算法基础上，提出利用卷积神经网络对低分辨率图像进行超分辨率重建方法（SRCNN），董超首次把 SRCNN 引入到超分辨率重建任务中，这种方法把传统方法中所采取的分步处理图像的步骤，都整合到 SRCNN 这一个深度学习网络模型中，大大减少重建流程。相较于传统基于机器学习的超分算法，SRCNN 对提升超分辨率重建具有标志性意义，但是 SRCNN 重建得到的 HR 图像仍然还存在纹理模糊等问题。之后他在 SRCNN 网络的基础上，提出了快速超分辨率卷积神经网络（FSRCNN），FSRCNN[48]模型去掉了 SRCNN 模型的 LR 缩放中预处理操作，并且将 SRCNN 网络深度进一步加深，利用更深的映射层对图像的特征进行抽取。Gwang-Young Youm 等人[49]在董超的基础上，提出多通道输入卷积神经网络的超分辨率方法（MC-SRCNN），这种网络模型输入多通道图像，能够更好的保留图像的高频信息。Wenzhe Shi 等人[50]提出了 ESPCN 算法进行超分辨率重建， ESPCN 网络中直接输入低分辨率图像到网络中，然后在图像上进行卷积操作从而获取高分辨率图像，大大提高了超分辨率重建的效率，该网络同时提出了亚像素卷积操作的过程。

随着 Goodfellow 首次提出 GAN 的概念，该模型的也逐渐被应用到图像超分辨

中国知网 https://www.cnki.net

率重建领域, Christian Ledig 等人[51]提出将生成对抗网络应用到 SR 问题中，SRGAN 方法[51]则通过牺牲峰值信噪比来生成图像中更多细节，增加真实感。已有的神经网络算法大多实现对放大倍数较小的图片进行重建工作，但是对于那些遇到放大 4 倍以上的图像，在对他们进行超分辨率重建过程中，容易使得重建结果过于平滑，从而缺少了细节真实感。

1.3 本文主要研究工作

1.3.1 主要研究内容

本文从解决实际工程项目中，在进行红外目标检测、跟踪研究时，存在数据严重不足、数据难以获取等情况，通过分析传统红外图像仿真生成方法具有流程复杂、成本高昂、效率低，难以进行大规模红外图像仿真生成等局限性，研究利用深度学习方法进行红外图像仿真生成工作研究。针对 CycleGAN 网络仿真红外图像的过程会出现生成的红外图像过拟合现象，提出在 CycleGAN 网络中，增加抑制器网络结构模块，用于反向抑制生成器网络生成过程的过拟合失真现象；针对 CycleGAN 网络在仿真红外图像过程中，理论上一条路径生成的结果与另一条路径重建的结果应该是一致的，但是实际生成过程中可能存在差别，而原始 CycleGAN 网络并未对其进行比较，为此在 CycleGAN 网络中增加损失函数项，用于计算一条路径生成图像与另一条路径循环重建出的图像间的差距；针对 CycleGAN 网络在仿真红外图像中，对细粒度特征的生成不够，为了提高生成红外图像的细节，提出引入注意力模块，用于加强对细节特征的生成。

考虑到仿真生成的红外图像以及实拍的红外图像通常存在分辨率低、图像信息不够丰富，为了能在分辨率更高的成像条件下进行红外图像目标检测识别，研究通过深度学习方法，对仿真的红外图像进行进一步处理，从而得到质量更高、分辨率更高、图像信息更加丰富的红外图像。针对原始 SRGAN 网络对红外图像的底层信息关注不够，可能会丢失红外图像的底层信息，借鉴 DenseNet[52]思想，改进 SRGAN 网络的生成器，采用密集链接方式，防止在超分辨率重建中对底层细节特征丢失，

中国知网 https://www.cnki.net

同时防止出现梯度爆炸的情况；针对红外图像中边缘纹理信息具有极为重要的作用，本文提出在改进 SRGAN 网络的损失函数中，增加用于计算边缘梯度损失的损失函数项，使得超分辨率重建出的红外图像边缘、纹理更清晰。

1.3.2 内容安排

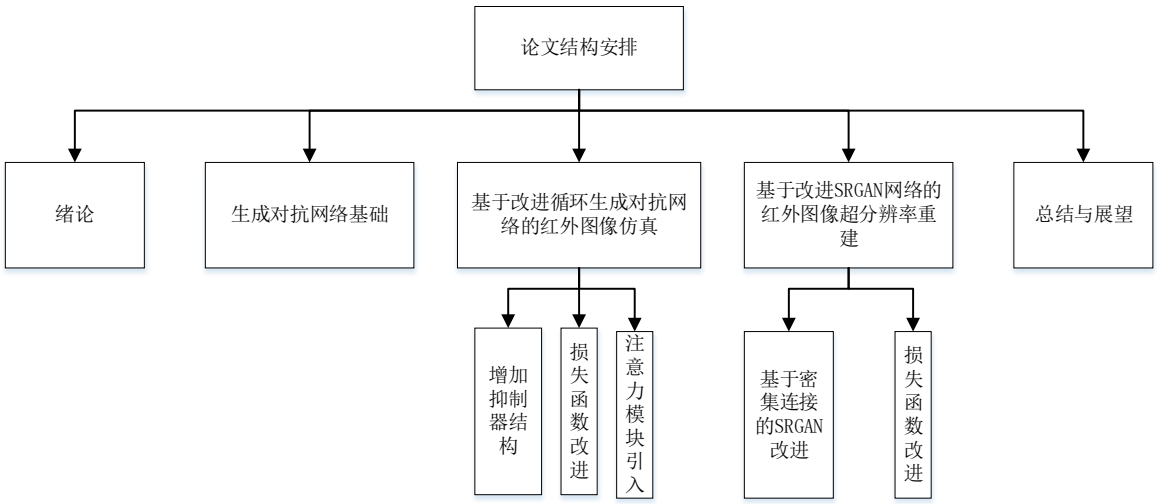

图 1-2 本文结构框架图

本文如图 1-2 所示，一共分成五章，内容安排如下：

第一章：绪论

主要分析对比基于物理模型的红外图像仿真方法，以及基于学习方法的红外图像仿真方法的国内外研究概况，并通过对比各种方法的优劣决定使用深度学习方法进行红外图像仿真生成工作。之后分析对比基于传统方法的图像的超分辨率重建，以及基于学习方法的图像的超分辨率重建工作，并通过对比各种方法的优劣，决定利用深度学习方法进行红外图像的超分辨率重建工作。

第二章：基本原理

本章首先介绍生成对抗网络的基础理论，之后对 CycleGAN 网络进行红外图像生成的基本原理，以及 SRGAN 网络进行超分辨率重建工作的基本原理进行简单概述，最后介绍本文将使用的公共评价指标。

第三章：基于改进循环生成对抗网络的红外图像仿真

中国知网 https://www.cnki.net

本章首先详细介绍 CycleGAN 网络具体网络结构以及损失函数，之后分析应用原始 CycleGAN 网络仿真生成红外图像的不足。接着分别提出：（1）在原始 CycleGAN 网络中增加抑制器模块 S，（2）在 CycleGAN 网络中增加计算通路的损失函数项，用于计算一条路径生成的图像与另一条路径重建的图像间的差距，（3）在 CycleGAN 网络中引入注意力模块（CBAM），三种递进的 CycleGAN 网络改进方案，增加仿真得到的红外图像的质量。对于改进 CycleGAN 网络仿真的红外图像，分别从 PSNR、SSIM 评价指标、仿真生成的红外图像的材质的灰度特性，以及生成的红外图像在实际目标检测中的可应用性三个角度，分别对仿真得到的红外图像进行实验探究。

第四章：基于改进 SRGAN 网络的红外图像超分辨率重建

本章首先详细介绍 SRGAN 网络具体网络结构以及损失函数，之后分析利用原始 SRGAN 网络进行红外图像的超分辨率重建工作的不足。接着分别提出：（1）在 SRGAN 网络中借鉴 DenseNet 思想，对生成器网络进行改进，使用密集接的方式防止在红外图像超分过程中底层信息的丢失；（2）在 SRGAN 网络的损失函数中，增加用于计算边缘梯度的损失函数项。两种递进的 SRGAN 网络改进方案，增加红外图像超分辨率重建的质量。最后分别从 PSNR、SSIM 评价指标角度，对超分辨率重建的红外图像进行评价，同时通过实验对比分析未经超分辨率重建的红外图像、原始 SRGAN 超分重建出的红外图像，以及应用改进 SRGAN 网络超分重建出的红外图像，在红外图像的目标检测中，尤其是当目标检测网络的训练样本较少时所起到的意义。

第五章：总结与展望

对本文工作进行总结，针对红外图像仿真生成以及对红外图像进行超分辨率重建中，存在的问题进行说明，并对未来研究工作提出展望。

中国知网 https://www.cnki.net

2 基本原理

本文将使用改进 CycleGAN 网络进行红外图像的仿真生成工作，以及利用改进 SRGAN 网络对红外图像进行超分辨率重建工作。这两种网络都是基于最基本的 GAN 网络发展而来的，为了后文能更好的说明这两种网络的工作原理，本章将首先对原始 GAN 网络的原理以及 GAN 网络进行数据拟合的基本过程进行简述，之后对 CycleGAN 网络进行红外图像仿真生成的基本原理，以及 SRGAN 网络对红外图像进行超分辨率重建的基本原理进行简述。

2.1 生成对抗网络原理

生成对抗网络(GAN)[19]属于无监督学习网络，不需要人为干涉，因此对输入数据没有过多限制，但是输入数据不能太自由，否则会出现 GAN 训练过程不稳定，容易发生模式崩溃等问题。目前生成对抗网络在图像生成、视频预测、行人重识别、超分辨率重建领域都有着很好的应用。GAN 网络的核心思想是零和博弈，网络结构如图 2-1 所示主要由两个网络组成：生成器网络（G）和判别器网络（D）。G 网络用于学习真实数据或者图像的特征分布情况，从而生成对应的数据或图像，D 网络用于区别生成器生成的结果与真实数据或图像之间的差别。

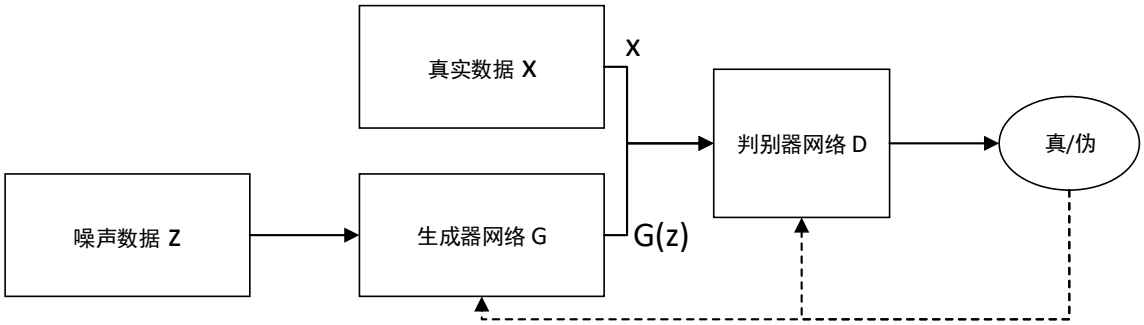

图 2-1 生成对抗网络工作过程示意图

最初版本的生成对抗网络中生成器 G 首先接收一个噪声 z，之后通过生成网络生成一个新的数据特征分布 G(z); 判别器网络 D 用来比较生成器网络 G 生成的数据和真实数据之间的差异。默认情况下真实数据的概率是趋近于 1，而生成器生成的数

中国知网 https://www.cnki.net

据的概率趋近于 0 时，即认为生成器生成的数据是假的，判别器网络 D 参数调整后，把结果反馈给生成器网络 G，接着 G 网络进行进一步调整，循环往复，直到生成器生成的数据的，被判别器网络 D 认为置信度是接近 1 时为止。

生成对抗网络训练过程如图 2-2 所示：

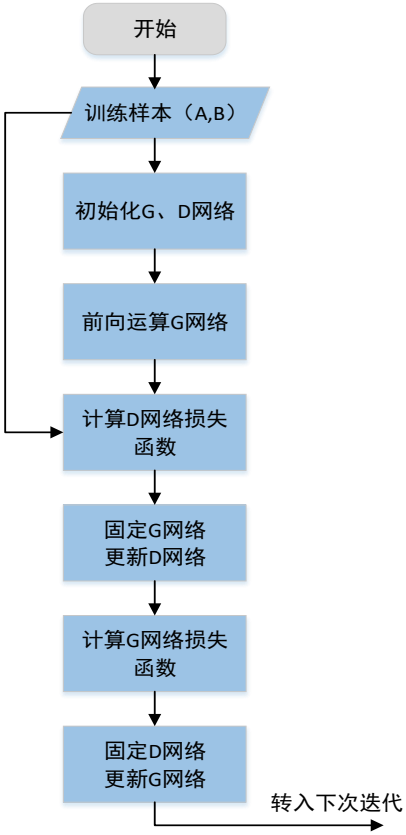

图 2-2　生成对抗网络训练过程

生成对抗网络的损失函数如式（2-1）所示：

$$\begin{aligned} V(D,G) &= E_{x\sim P_{data}}[\ln D(x)] + E_{z\sim P_G}[\ln(1-D(G(z)))] \\ &= [\int_x P_{data}(x)\ln D(x) + P_G(x)\ln(1-D(x))]dx \end{aligned} \tag{2-1}$$

其中：

D 表示生成器，G 表示判别器，x 表示真实数据，z 表示噪声数据。

这个式子的好处在于，固定生成器网络 G，则 $\max V(G,D)$ 就表示生成数据 P_G 和真实数据 P_{data} 之间的差异，然后调整得到一个更好的生成器 G，使得 $V(D,G)$ 最大值最小，也就是两个分布之间的差异最小，即：

中国知网 https://www.cnki.net

$$G^{*}=\arg\min_{G}\max_{D}V(D,G) \tag{2-2}$$

对式（2-2）分析可知，D 网络要让 $V(D,G)$ 尽可能的大，也就是对于真实数据 x，$D(x)$ 要接近 1，对于生成器 G 生成的数据 x，$D(x)$ 要接近 0，而生成器 G 要让式子尽可能小，让来自生成分布的 x，$D(x)$ 尽可能接近 1。生成对抗网络的实现数据拟合过程示意图可以参考图 2-3 所示：

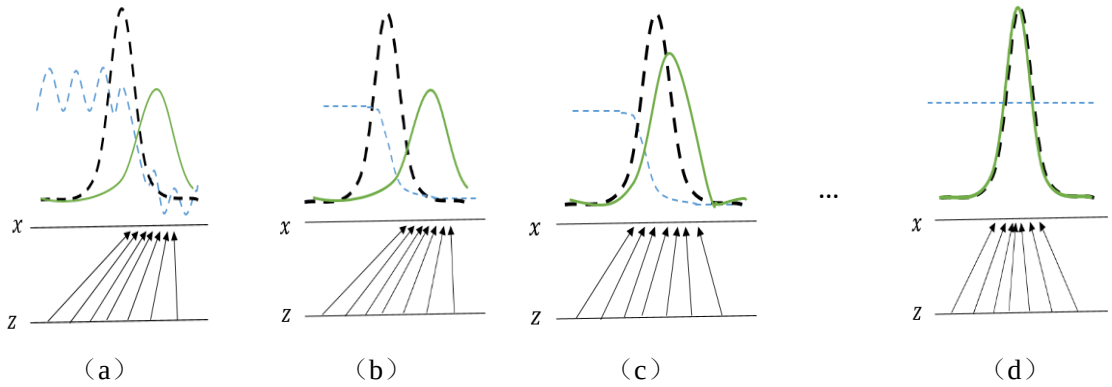

图 2-3　生成对抗网络数据拟合过程示意图

在图 2-3 中，x 表示数据分布，z 是均匀采样的噪声，判别器网络模型 D 的分布情况用蓝色虚线表示，生成器网络模型学习的数据分布情况 p_g 用绿色实线表示，真实数据分布情况 p_{data} 用黑色虚线进行表示。在图（a）中 p_g 与 p_{data} 存在相似性，但是从图中可以看出并没有收敛，判别器 D 只能部分判别准确；图（b）中，通过固定生成器网络 G，更新判别器网络 D，使得判别器网路收敛到了 $D^{*}(x)=\dfrac{p_{data}(x)}{p_{data}(x)+p_g(x)}$，在图（c）中，固定判别器网络 D，对生成器网络 G 进行更新，使得判别器的梯度能够引导生成器网络生成的数据，向着能被 D 网路分类为真实数据区域的方向移动；在图（d）中经过若干次训练之后，生成器网络和判别器网络接近 $p_g=p_{data}$，此时 D 网络将无法再将生成器网络生成的数据判别为假。

2.2 CycleGAN 网络原理

深度学习方法能够通过对给定数据样本的自主学习获得未知函数或数学模型的估计。生成对抗网络是深度学习中进行图像生成与转换最常见且最有效的形式之一，

中国知网 https://www.cnki.net

通过生成对抗网络的方法，从给定的大量样本中学习两个图像域之间的映射关系，通过大量网络参数[54]，拟合出不同材质可见光图像到红外图像间的复杂变化函数，从而达到仿真生成红外图像的目的。

循环生成对抗网络（CycleGAN）是生成对抗网络中自带环形结构的一种，能够很好地实现在配对或非配对训练集情况下的红外图像仿真生成工作。CycleGAN[25]由两个生成器 G、F，以及两个判别器模块 D_X 、D_Y 组成网络，它的目的是通过学习 X 域（可见光图像）与 Y 域（红外图像）两组不同风格的图片间的映射关系，实现两个域图像间的相互转换过程。可见光图像经过 G 网络后生成图片 G(X)，原则上 $G(X)\in Y$，以此类推红外图像经过 F 网络后，生成的图片 $F(Y)\in X$ 。此外如图 2-4 所示，CycleGAN 同时学习 G 和 F 两个生成器网络的映射，并要求可见光图像转换为红外图像之后，应该还可以转换回来为可见光图像；同理红外图像转换到可见光图像之后，应该还可以转换回来为红外图像，图 2-5 所示为循环生成对抗网络生成红外图像过程示意图。

CycleGAN 网络生成红外图像的具体工作过程为：

（1）训练生成器网络 G，将输入的可见光数据 X 转换为红外图像数据 $\hat{Y}$，训练生成器网络 F，将输入的红外数据 Y 转换为可见光图像数据 $\hat{X}$；

（2）训练判别器网络 D_X，用于区分判别生成的红外图像数据 $\hat{Y}$，是否为红外图像数据，训练判别器网络 D_Y，用于区分判别生成的可见光数据 $\hat{X}$，是否为可见光图像数据；

（3）同时通过网络的循环机制，将生成的红外图像数据 $\hat{Y}$，通过生成器网络 F，重建为可见光图像数据 $\hat{X}$，同时通过判别器网络 D_Y 用以区分判别，将生成的可见光图像数据 $\hat{X}$，通过生成器网络 G，重建为红外图像数据 $\hat{Y}$，同时通过判别器网络 D_X 用以区分判别。

中国知网 https://www.cnki.net

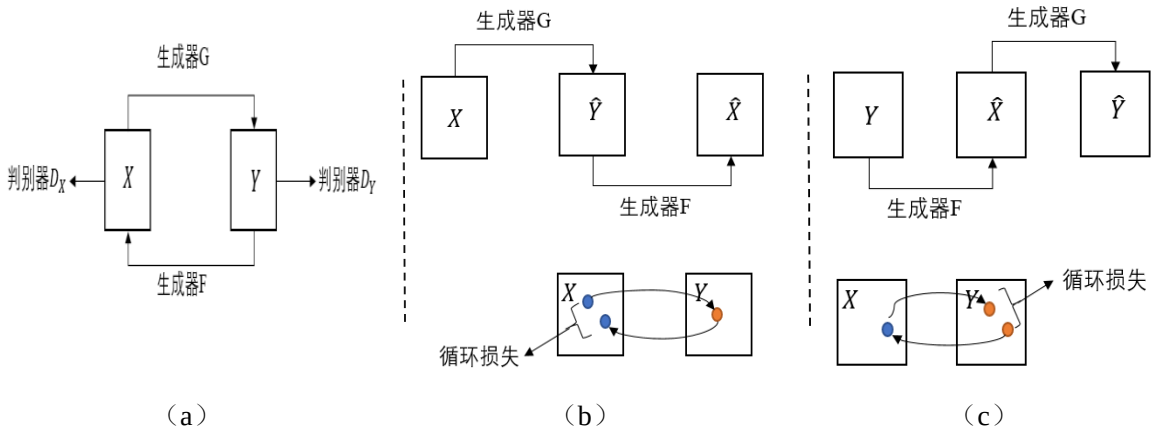

图 2-4　循环生成对抗网络工作示意图

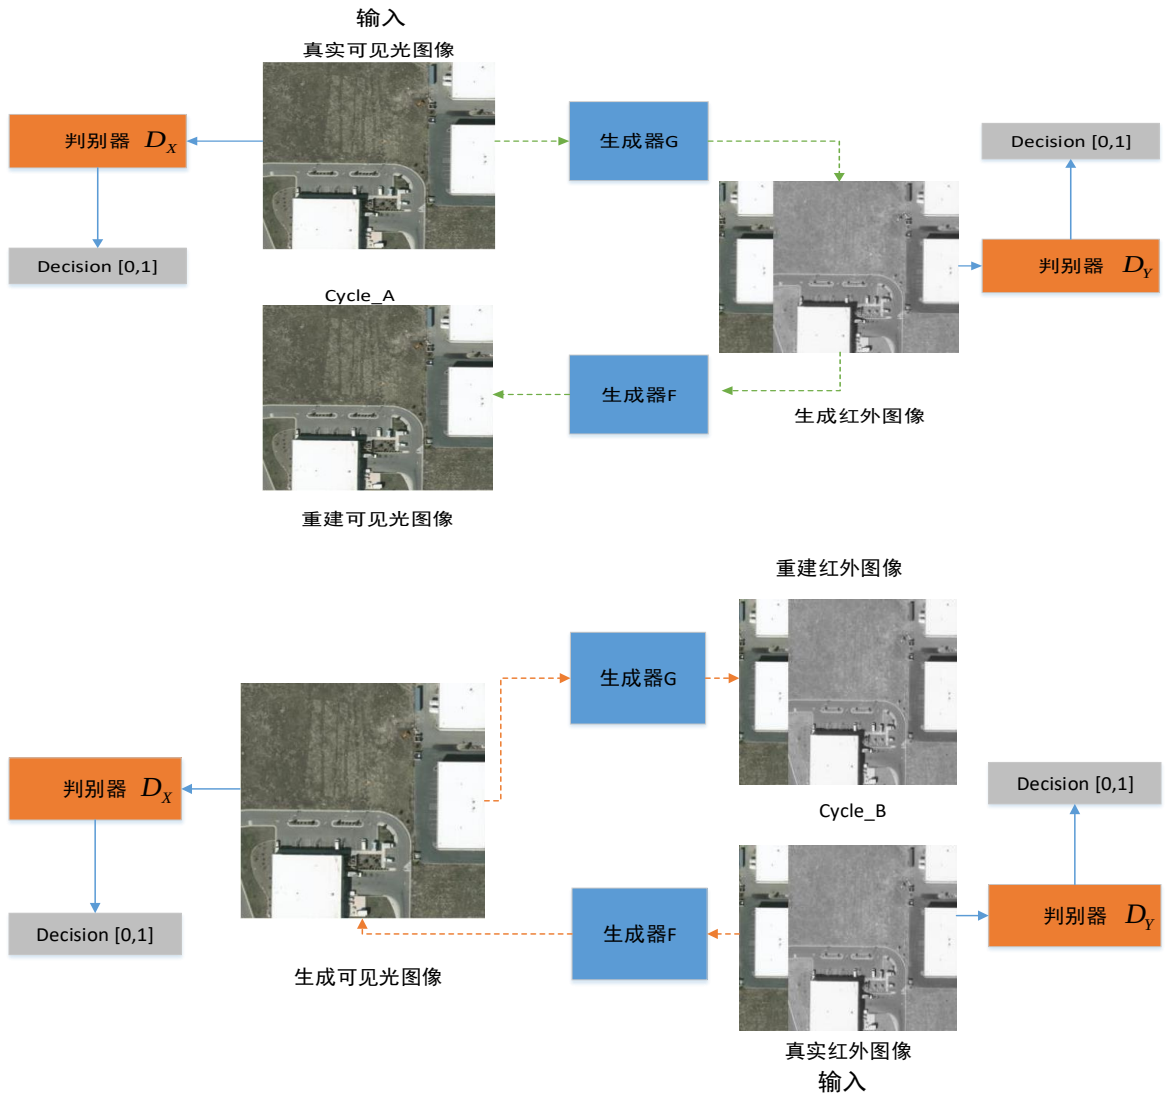

图 2-5　循环生成对抗网络生成图像过程示意图

中国知网　https://www.cnki.net

2.3 SRGAN 网络原理

在实际使用时，由于此前所使用的红外成像器分辨率低、成像质量不高，利用该数据通过改进 CycleGAN 生成的部分红外图像也通常伴随着分辨率低的问题。为了能在较高分辨率成像条件下，进行红外图像的检测识别任务，需要对红外图像进行超分辨率重建工作。利用深度学习方法对图像进行超分辨率重建工作，能够获得比传统方法更好的超分辨率重建效果。目前很多研究者都在利用深度学习进行图像的超分重建工作研究，SRGAN[51]的作者注意到使用 CNN 网络进行图像的超分辨率重建工作，使用最小化均方误差作为内容损失，这样超分辨率重建的结果虽然可以获得较高的 PSNR 值，但是存在高频细节丢失的问题。因此 SRGAN 网络的作者认为应当从低层次像素，到高层次风格、整体特征和抽象特征上超分辨率重建的结果，和真实高清图像都应该是接近的，并在 SRResNet[51]网络模型的基础上，采用感知损失和对抗损失，从而使得生成的图片与目标高清图像在风格以及语义上更相似的 SRGAN 网络的结构。

SRGAN 网络模型由两部分组成：生成网络和判别网络。生成网络用来生成高分辨率图像，判别网络则负责判断输入的图像是否为高分辨率图像，同时对两个网络进行训练，两个网络之间属于对抗关系，生成网络要尽可能生成能欺骗过判别网络的重建图像，判别网络要尽判别出“假图像”，最终达到生成网络可以生成出判别网络无法区分的高分辨率图像的目的。

SRGAN 网络对单幅红外图像进行超分辨率重建具体过程可以理解为：以 HR 表示真实高分辨率图像，以 LR 表示低分辨率图像，以 SR 表示对应的高分辨率通过网络训练重建生成的高分辨率图像。在训练过程中，LR 是通过 HR 应用一个下采样因子为高斯滤波器得到的。生成器网络 G 通过学习 LR 与 HR 之间的映射关系，生成高分辨率图像 SR，而判别器网络 D 用以判别区分 SR 是否属于高分辨率图像。对超分重建的图像质量的评价，主要有两个指标，PSNR（峰值信噪比）和 SSIM（结构相似性），PSNR 是评价图像的客观指标。但是 PSNR 的分数无法和人眼看到的视觉感知完全一致，有可能 PSNR 较高的图像，反而比 PSNR 较低者差。所以 SRGAN

中国知网 https://www.cnki.net

网络使用新的感知损失来定义网络的损失函数，从而达到更好的视觉效果，SRGAN 网络进行红外图像超分辨率重建过程如图 2-6 所示。

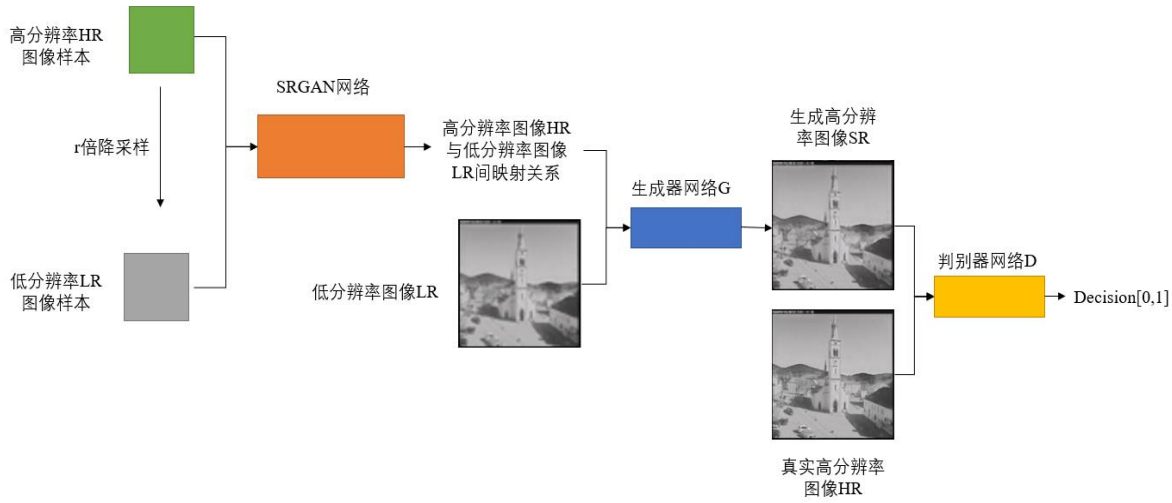

图 2-6　SRGAN 网络进行红外图像超分辨率重建过程

2.4 评价指标

在应用深度学习方法进行图像仿真以及超分辨率重建领域中，一般通过主观评价以及客观评价两个角度对生成的图像进行评价，其中主观评价不需要进行复杂的计算，主要通过人眼直接观察，对比生成的图像与真实图片之间的差距，但是主观评价往往很难较为真实、全面的对仿真生成图像或者超分辨率重建的图像进行比较，因此往往还需要根据视觉系统建立相应的数学模型，对图像进行客观评价。在应用深度学习方法对红外图像进行评价中，常用的评价方法有峰值信噪比（PSNR）、结构相似性（SSIM）等。

（1）峰值信噪比（PSNR）

图像的信噪比 SNR 等于信号和噪声功率谱之比，峰值信噪比 PSNR 指的是信噪比 SNR 的最大值。SNR 值越高说明图像中包含的信息对于噪声比值的功率越大。失真图像的信号功率可以用失真图像的像素平方表示，真实红外图像和仿真得到的红外图像的 MSE 可以用来表示噪声功率。通常 SNR 以及 PSNR 使用 dB 作为单位。当

中国知网　https://www.cnki.net

仿真得到的红外图像与真实红外图像之间的 PSNR 值很大时，说明 MSE 值很小，这种情况下便可以认为二者相似，效果越好，其计算公式如下：

$$SNR=\frac{S}{MSE}=10\log\left(\frac{\frac{1}{N\times M}\sum_{i=0}^{N-1}\sum_{j=0}^{M-1}f(i,j)^2}{\frac{1}{N\times M}\sum_{i=0}^{N-1}\sum_{j=0}^{M-1}[f(i,j)-f_s(i,j)]^2}\right) \tag{2-3}$$

$$PSNR=10\log\left(\frac{f_{peak}^2}{\frac{1}{N\times M}\sum_{i=0}^{N-1}\sum_{j=0}^{M-1}[f(i,j)-f_s(i,j)]^2}\right)$$

其中 $f(i,j)$ 表示生成像素，$f_s(i,j)$ 为标准图像像素，$N\times M$ 为图像大小。由于红外图像是八位灰度图，因此这里令 f_{peak} 其取值为 255，即：$f_{peak}^2=255^2$ 。

（2）结构相似度（SSIM）

SSIM 用于衡量两幅图像之间的相似度， SSIM 是对两幅图像（仿真得到的红外图像和真实的红外图像）之间的方差、均值、协方差进行综合计算得出，SSIM 取值范围是[0,1]。对于 SSIM 计算得到的结果越大，说明仿真生成红外图像和真实红外图像的结构相似性越高，当 SSIM 计算的结果为 1 时，表示仿真的图像和真实图像完全一致，这里的结构信息便是符合人平时观测时注意到的纹理结构信息。

SSIM 的定义公式为：

$$SSIM(x,y)=\frac{(2\mu_x\mu_y+c_1)(2\sigma_{xy}+c_2)}{(\mu_x^2+\mu_y^2+c_1)(\sigma_x^2+\sigma_y^2+c_2)} \tag{2-4}$$

其中，x 表示真实红外图像，y 表示仿真生成的红外图像，σ_x^2,σ_y^2 用来分别表示真实红外图像，仿真生成的红外图像的方差，σ_{xy} 是两者的协方差，μ_x,μ_y 用来分别表示真实红外图像、仿真生成的红外图像的平均值。而 $c_1=(k_1L)^2,c_2=(k_2L)^2$ 则用来表示维持稳定的常数，其中 L 是灰度的最大值，由于红外图像属于八位灰度图，因此这里 L 取 255，而 k_1 和 k_2 两个是远小于 1 的常数，本文将其分别取值为 0.01,0.03 。

2.5 本章小结

为了后面更好地研究利用改进 CycleGAN 网络仿真生成红外图像，以及利用改进 SRGAN 网络对仿真生成的低分辨率红外图像进行超分辨率重建工作。本章首先

中国知网 https://www.cnki.net

介绍生成对抗网络的基本理论，之后对本文将使用的 CycleGAN 网络仿真生成红外图像的原理与过程，以及 SRGAN 网络对红外图像进行超分辨率重建过程的基本原理与过程进行简要描述，最后交代本文使用的评价指标。

中国知网 https://www.cnki.net

3 基于改进循环生成对抗网络的红外图像仿真

基于传统物理方法的红外仿真技术，虽然能够获得较为真实的红外图像数据，但是整个过程较为繁琐，且难以适用于大规模红外图像的生成过程，而生成对抗网络可以通过大量网络参数拟合出可见光图像与红外图像间的映射关系，实现将可见光图像转换为相应红外图像的目的。循环生成对抗网络（CycleGAN）由于其自身具有环形网络结构，可以同时满足使用非配对数据或者配对数据作为训练集进行红外图像仿真生成的工作。循环生成对抗网络在进行同域图像的转换能取得很好的效果（例如一种风格的可间光图像转化为另一种风格的可见光图像），但是当进行可见光图像到红外图像，这种不同域的图像生成工作时，容易在部分生成的结果中出现整体失真、局部错误映射等问题，为此本章提出对 CycleGAN 网络增加抑制器模块、损失函数的改进以及引入注意力模块递进的改进方案，提高仿真红外图像的效果。

3.1 循环生成对抗网络

3.1.1 循环生成对抗网络结构

CycleGAN[25]由两个生成器 G、F，以及两个判别器模块 D_X 、D_Y 组成网络组成。其中 CycleGAN 的生成器网络结构，为类似 U-Net[53]网络结构，生成器生成图像过程如图 3-1 所示，生成器网络组成如图 3-2 所示。

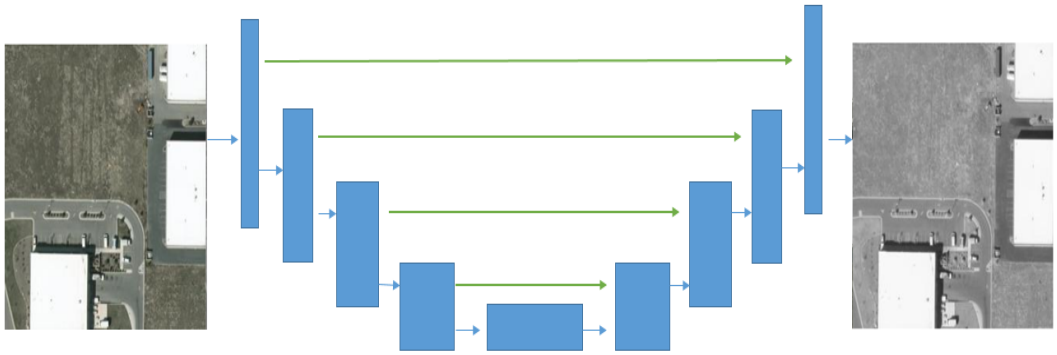

图 3-1　生成器生成图像过程

中国知网　https://www.cnki.net

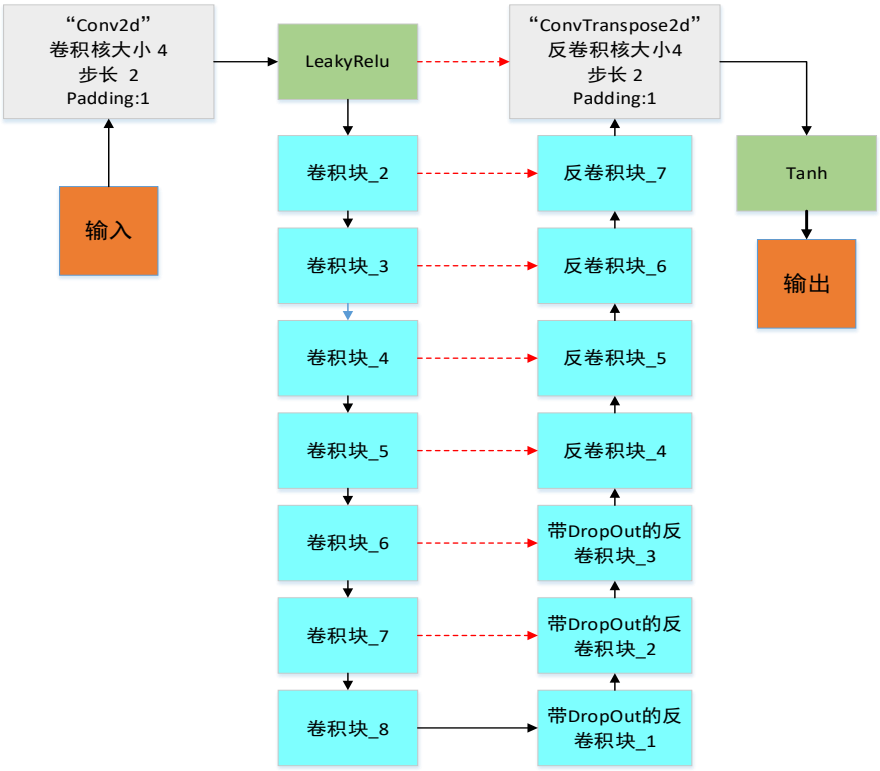

图 3-2　生成器网络组成

从图 3-2 中网络组成可以看出该生成器网络形状为“U”子形，上图中，红色箭头为类似 ResNet[55]的跨接操作，用于提高网络宽度，提高网络的表达能力。即：将当前卷积层输出特征图和解码器对应层的输出特征图进行融合，该操作仅在通道维度上进行堆叠，不进行其他操作，其示意图 3-3 所示：

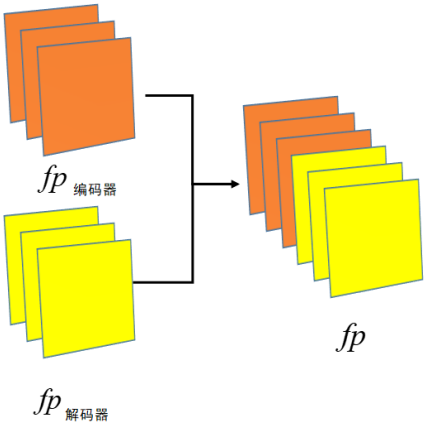

图 3-3　通道融合实现原理

中国知网　https://www.cnki.net

其中 $fp_{编码器}$ 表示编码器当前层输出尺寸为 $N\times C1\times H\times W$ 的特征图， $fp_{解码器}$ 表示解码器当前层输出尺寸为 $N\times C2\times H\times W$ 的特征图，通过通道融合操作后输出尺寸为 $N\times(C1+C2)\times H\times W$ 的特征图 fp，其中 N 表示 BatchSize 大小，特征图的高和宽分别用 H、W 进行表示。

判别器网络组成如图 3-4 所示：

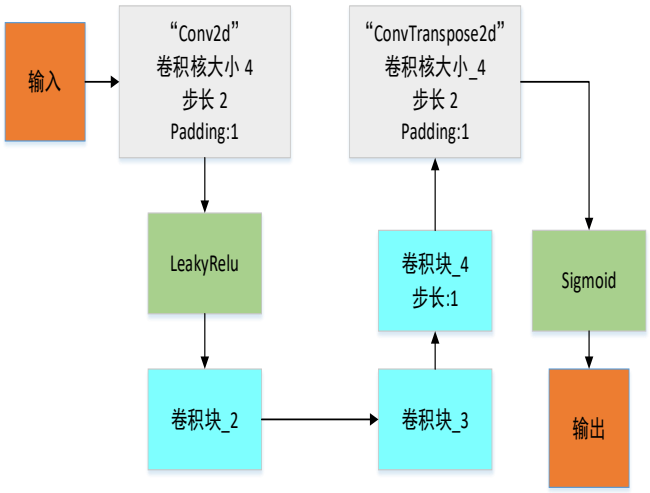

图 3-4　判别器网络组成

其中卷积块、反卷积块、带 DropOut 的反卷积块三个模块的示意图 3-5 中 (a)、(b)、(c)所示，卷积模块，通过卷积层、BN 层以及 LeakyRelu 三部分组成；卷积模块，由反卷积、BN 层和 LeakyReLU 三部分组成；带 DropOut 的反卷积块是在反卷积的基础上添加一个 DropOut 操作。

（a）

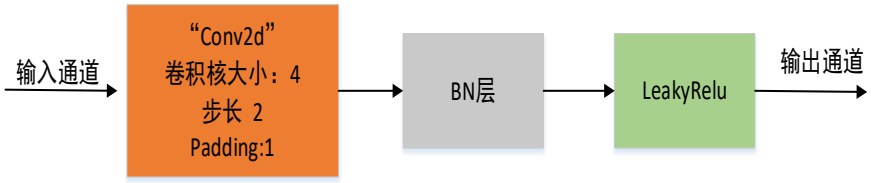

卷积模块示意图

中国知网 https://www.cnki.net

（b）

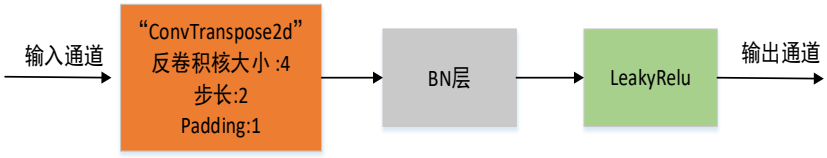

反卷积模块示意图

（c）

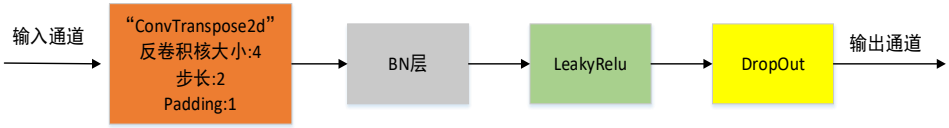

带 Dropout 反卷积模块示意图

图 3-5　卷积、反卷积以及带 Dropout 的反卷积模块示意图

整个循环生成对抗网络的损失函数如式（3-1）所示：

$$L(G,F,D_X,D_Y)=L_{GAN}(G,D_Y,X,Y)+L_{GAN}(F,D_Y,Y,X)+\lambda L_{\text{cyc}}(G,F) \tag{3-1}$$

其中：L_{cyc} 为循环损失

$$L_{GAN}(G,D_Y,X,Y)=E_{y\sim P_{data(y)}}[\log(D_Y(y))]+E_{x\sim P_{data}}[\log(1-D_Y(G(x)))] \tag{3-2}$$

$$L_{GAN}(F,D_Y,X,Y)=E_{x\sim P_{\text{data}(x)}}[\log(D_X(x))]+E_{y\sim P_{data(y)}}[\log(1-D_X(G(y)))] \tag{3-3}$$

$$L_{cyc}(G,F)=E_{x\sim P_{data(x)}}[\|F(G(x))-x\|_1]+E_{y\sim P_{data(y)}}[\|G(F(y))-y\|_1] \tag{3-4}$$

其中：

x 表示训练样本中真实红外图像，而 y 则表示训练样本中真实可见光图像，G 表示第一个生成器，F 表示第二个生成器，D_X 表示第一个判别器，D_Y 表示第二个判别器，L_{GAN} 表示生成判别过程损失函数，L_{cyc} 表示循环一致性损失函数。

3.1.2　原始 CycleGAN 网络的缺点

原始 CycleGAN 通过对数据集进行学习，拟合出两个域图像的映射关系，该方法在对可见光这种同域的图像进行风格转换迁移时，能够取得了较为不错的实验效果。但是将该方法应用到通过可见光图像仿真生成红外图像时，在生成的部分红外图像中，虽然也能够仿真生成较好的红外图像效果。但在部分生成的红外图像中，还是会出现存在局部错误映射、图像整体质量差等现象，生成红外图像细节保持不

中国知网　https://www.cnki.net

够等现象。即在图 3-6 中，（a）仿真生成的红外图像中出现了较为明显的条纹状噪声；（b）仿真生成的红外图像整体失真较为严重，较为模糊。

造成这种现象的原因可能为：（1）网络只通过判别器 D 网络对生成器生成的结果进行判别，但是可能出现生成器生成的图像过拟合，但是却仍然被判别器网络认为是正确的，并未能够区分出来；（2）理论上一条路径生成的图像和另一条路径重建的图像应该是一样的，但实际生成过程中可能存在误差，而原始 CycleGAN 网络并没有对这两个结果进行比较；（3）原始 CycleGAN 网络在生成图像过程中，对细粒度特征的关注度不够。由此可见使用原始 CycleGAN 网络进行本章红外图像的生成工作，存在一定的不足，下面将对传统网络结构进行改进。

可见光图像　　原始 CycleGAN 生成红外图像

(a) 仿真生成的红外图像中出现了较为明显的条纹状噪声

(b) 仿真生成的红外图像整体失真较为严重,较为模糊

图 3-6　基于原始 CycleGAN 仿真得到的红外图像

中国知网　https://www.cnki.net

为此本章针对原始 CycleGAN 网络只通过判别器 D 网络，来对生成器生成的结果进行判别，但是可能出现生成器生成的图像过拟合，但是却仍然被判别器网络认为是正确的，并未能够区分出来问题，提出在增加抑制器模块，用来抑制生成图像的过拟合现象；针对一条路径生成的图像和另一条路径重建的图像理论上应该是一样的，但实际生成过程中可能存在误差，而原始 CycleGAN 网络并没有对这两个结果进行比较问题，本章提出对损失函数进行改进，建立一条路径生成结果与另一条路径重建结果的比较；针对原始 CycleGAN 网络在生成图像过程中，对细粒度特征的关注度不够问题，本章提出在生成器网络中添加注意力模块（CBAM），加强网络对细粒度特征的关注度。

3.2 循环生成对抗网络改进

3.2.1 增加抑制器结构

由于可见光转换为红外图像的过程中，没有其他约束器对其进行约束，以至于最后虽然 CycleGAN 网络整体的损失函数已经收敛了，但是最终生成部分图像整体质量并不理想，甚至部分图片中在局部生成了错误的红外图像，但是判别器网络结构最终还是将这部分错误结果判定为红外图像。针对生成器网络在生成红外图像过程中，存在过拟合失真的问题，本章提出在原始 CycleGAN 网络中增加抑制器网络结构 S。增加抑制器网络结构 S 后，CycleGAN 网络的生成过程将变为两步进行：首先可见光图像图像经过 G 网络生成对应红外图像，之后再经过 S 网络进行图像反向验证，生成器能够一边学习两个域之间的映射，一边希望转换后的图片转换回来后，能尽可能少的发生改变。从而对生成过程进行优化，生成精细化的转换效果，抑制图像的过多改变。即输入的红外图像在通过生成器后，得到可见光图像, 之后该可见光图像通过抑制器 S 得到红外图像, 理论上如果生成器网络没有过拟合的情况下，经过抑制器 S 得到后得到的红外图像，与输入红外图像完全一致的。同理对于输入的可见光图像, 其生成的红外图像再经过抑制器 S 后得到的可见光图像，与输入的可见光图像也应该是一致的，抑制器 S 的损失函数如式（3-5）所示，其中 S_1、S_2 分别代表网络两条路径上的抑制器结构。

中国知网 https://www.cnki.net

$$L_{tid}(G,S_1,S_2,F)=E_{x\sim Pdata(x)}[\|S_1(G(x))-x\|_1]+E_{y\sim P_{data(y)}}[\|S_2(F(y))-y\|_1] \tag{3-5}$$

之后将抑制器 S_1 对 G(x) 修正抑制后，得到的可见光图像［$G(x)-G(\|S_1(G(x))-x\|_1)$］结果，以及经过抑制器 S_2 对 F(y)修正抑制后，得到的红外图像［$F(y)-F(\|S_2(F(y))-y\|_1)$］结果，带入 CycleGAN 的损失函数（3-2）、（3-3）、（3-4）中，可得改进网络结构后 CycleGAN 的损失函数为：

$$\begin{aligned}L(G,S_1,S_2F,D_X,D_Y)&=L_{GAN}(G,S_1,D_Y,X,Y)+L_{GAN}(F,S_2,D_X,Y,X)\\&+\lambda L_{cyc}(G,S_1,S_2,F)+\beta L_{tid}(G,S_1,S_2,F)\end{aligned} \tag{3-6}$$

其中：

$$\begin{aligned}L_{GAN}(G,S_1,D_Y,X,Y)&=E_{y\sim Pdata(y)}[\log(D_Y(y))]\\&+E_{x\sim Pdata(x)}[\log(1-D_Y(G(x)-G(\|S_1(G(x))-x\|_1)))]\end{aligned} \tag{3-7}$$

$$\begin{aligned}L_{GAN}(G,S_2,D_x,Y,X)&=E_{x\sim Pdata(x)}[\log(D_X(x))]\\&+E_{y\sim Pdata(y)}[\log(1-D_X(F(y)-F(\|S_2(F(y))-y\|_1)))]\end{aligned} \tag{3-8}$$

$$\begin{aligned}L_{cyc}(G,S_1,S_2,F)&=E_{x\sim P_{data(x)}}[\|F(G(x)-F(\|S_1(G(x))-x\|_1))-x\|_1]\\&+E_{y\sim P_{data(y)}}[\|G(F(y)-G(\|S_2(F(y))-y\|_1))-y\|_1]\end{aligned} \tag{3-9}$$

其中：

λ、β 为参数，x 表示训练样本中真实的红外真实图像，而 y 则表示训练样本中真实可见光图像，G 表示第一个生成器，F 表示第二个生成器，D_X 表示第一个判别器，D_Y 表示第二个判别器，L_{GAN} 表示生成对抗网络损失，L_{cyc} 表示循环一致性损失，L_{tid} 表示转换损失函数。增加抑制器结构后 CycleGAN 网络生成图像过程为图 3-7 所示，其中（a）、（b）分别代表改进 CycleGAN 网络的两条路径。

中国知网 https://www.cnki.net

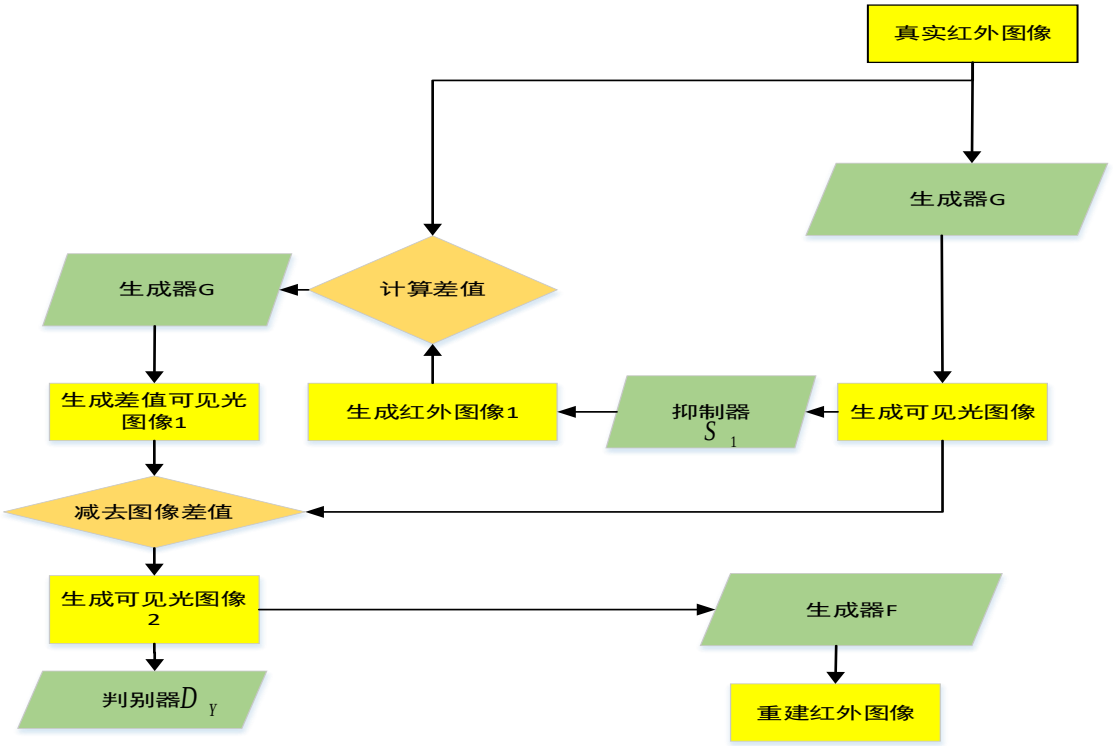

(a)

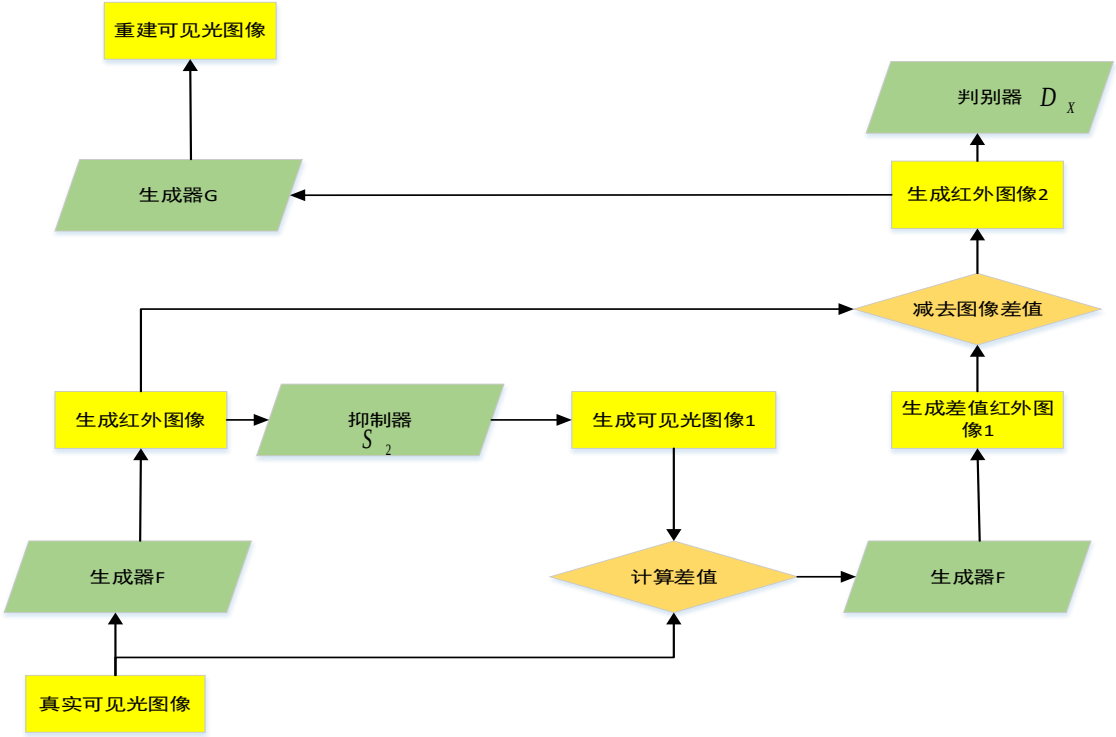

（b）

图 3-7　添加抑制器结构后 CycleGAN 网络生成图像过程

中国知网　https://www.cnki.net

其中本文抑制器网络结构设计如图 3-8 所示，该结构采用全卷积方式，不使用任何池化、上采样操作。在该抑制器结构中不同的卷积层代表不同尺度图像激活值，不同激活值表示不同尺度的图像。不同卷积层得到不同尺度的特征映射，高层的激活值表示整体图像的激活值，底层卷积层表示小的图像块的激活值。抑制器网络 S 本质上还是生成器网络，结构类似 DCGAN 网络[22]，但是在 CycleGAN 网络中抑制器 S 是独立于生成器 G、F，抑制器网络结构 S 结合式（3-5）所示的损失函数，能够实现对生成器 G、F 中生成图像过拟合失真的部分进行抑制的作用。

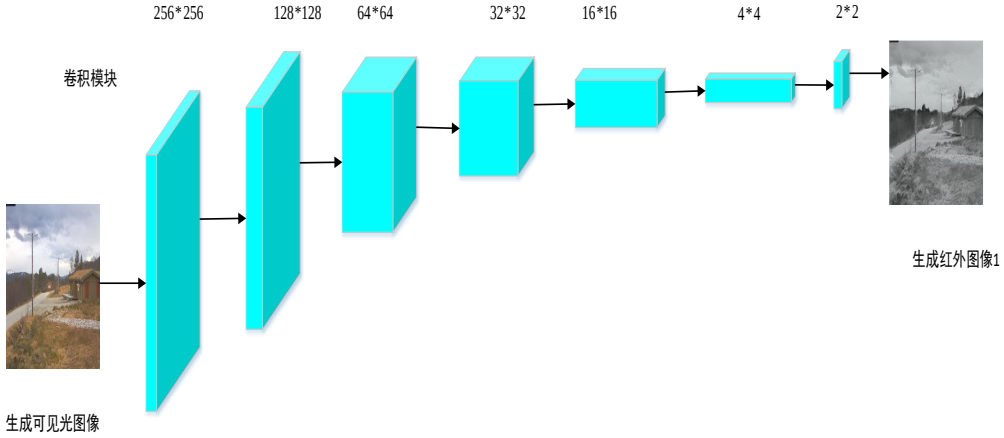

图 3-8　抑制器结构模型

3.2.2 损失函数的改进

在使用改进后的 CycleGAN 网络结构进行红外图像生成后， 理论上 CycleGAN 网络一条路径生成的图像和另一条路径重建的图像应该是一致的，但是在实际生成过程中却可能存在差别，而原始 CycleGAN 网络并未对这两项进行比较。结合在进行数据集转换时，循环一致性损失函数可以减少学习错误映射的几率，为了进一步强化这一过程的性能，本章增加用于计算生成路径以及重建路径的损失函数，强化对循环一致性损失约束，强化生成过程对图像细节特征保留，从而获得更好的红外图像生成能力。

考虑到生成器生成的红外图像和循环重建得到的红外图像是一个域的图像，生成的可见光图像和循环重建得到的可见光图像的是一个域的。因此本文提出在两条生成路径之间增加一个计算通路的损失函数，从而对 3.2.1 节的 CycleGAN 网络进行

中国知网 https://www.cnki.net

进一步的改进工作。这样就可以把生成器网络生成的图像与另一个路径重建得到的图像进行比较，理论上这两者应该是完全一致的，即生成的红外图像和重建出的红外图像理论上是一致的，生成的可见光图像和重建的可见光图像也应该是一致的。

添加生成重建通路损失函数，可以将图 3-7 中生成可见光图像 2 与重建可见光图像进行比较，将生成红外图像 2 与重建红外图像进行比较。理论上 CycleGAN 网络生成的可见光图像与循环重建的可见光图像，生成的红外图像与循环重建红外图像，理论上他们应该是分别相同的。为此本章使用 L_{sr} 计算图像之间的距离 L_1。即使用 L_{sr} 函数计算生成的可见光图像与循环重建出的可见光图像，生成的红外图像与循环重建得到的红外图像间的距离。因此得到式（3-10）所示的生成重建通路的损失函数为：

$$\begin{aligned} L_{sr}(F,G) = &\left\| F(y) - F(G(x) - G(\left\| S_1(G(x)) - x \right\|_1))) \right\|_1 \\ &+ \left\| G(x) - G(F(y) - F(\left\| S_2(F(y)) - y \right\|_1))) \right\|_1 \end{aligned} \tag{3-10}$$

其中 $F(y) - F(G(x) - G(\left\| S_1(G(x)) - x \right\|_1)))$ 计算生成的红外图像与循环重建的红外图像的 L_1 距离，$G(x) - G(F(y) - F(\left\| S_2(F(y)) - y \right\|_1)))$ 计算生成的可见光图像与循环重建的可见光图像的 L_1 距离。增加该损失函数后，不但对提升生成红外图像的质量，同时还能在一定程度上提高网络的稳定性，尤其是当权重 α 设置在[0,1]之间时，提升效果最佳。整个改进后网络的损失函数为：

$$L_{GAN} = L(G, S_1, S_2 F, D_X, D_Y) + \alpha L_{sr}(F,G) \tag{3-11}$$

其中：

α 表示参数，L_{sr} 表示生成重建通道的损失函数。

3.2.3 注意力模块引入

传统的网络卷积过程通过卷积核的大小，对图像像素进行操作，这种方式对图像的细粒度特征关注不够，注意的区域有限，容易在红外图像的细节上遗漏和生成一些错误样本。为此引入注意力模块[56]，注意力模块能够补充使得传统卷积网络，加强对细节特征的关注力度，加强生红外图像对细节的描述，提高神经网络对特征图中感兴趣区域的特征表征能力，能够产生具有较高分辨性特征，同时还能够大大

中国知网 https://www.cnki.net

加快计算效率。注意力模块(CBAM)[56]由通道注意力模块和空间注意力模块两部分组成。如图 3-9 所示：

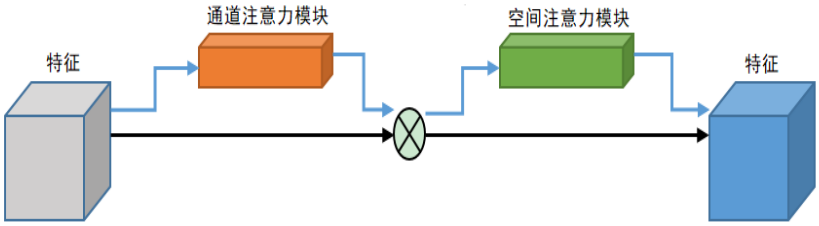

图 3-9　注意力模块结构示意图

整个特征图的自注意流程为：

$$F' = M_c(F) \otimes F$$
$$F'' = M_s(F') \otimes F' \tag{3-12}$$

其中 F 表示在注意力模块中输入的特征图，M_s 表示 CBAM 中的空间注意力模块，M_c 表示 CBAM 中的通道注意力模块，$\otimes$ 表示将逐像素乘法操作。

通道注意力模块是为了学习输入特征的通道之间的关系，学习对于输入的多通道特征或者图片，哪一项是重要的。其中每个特征通道，都可以被看作一个特征检测器。通道注意力模块中可以通过最大池化，和平均池化来对输入的特征图 F，在空间维度上进行压缩，得到两个不同空间描述符 F_{avg}^c 和 $F_{\max}^c$，分别用来表示平均池化和最大池化的特征，之后将 F_{avg}^c 和 $F_{\max}^c$ 发送到多层感知器中，将多层感知器输出的特征进行对应位相乘加和操作，之后再经过 sigmoid 激活函数操作，最后将得到生成通道注意力图 M_c 与 F 相乘，便可以得到通道关注的特征图 F'。全局平均池化是为了聚集整个特征平面空间的特征，而全局最大池化是为了提取整个特征平面的最大特征。于是得到通道注意力特征：

$$M_c(F) = \sigma(MLP(AvgPool(F)) + MLP(MaxPool(F))) \tag{3-13}$$

其中 F 表示注意力模块中输入的特征，σ 代表 sigmoid 操作，MLP 表示多层感知机。

中国知网 https://www.cnki.net

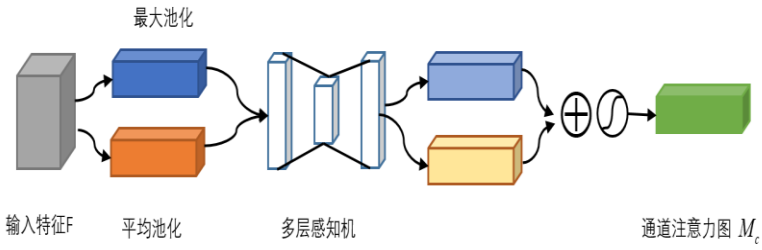

图 3-10　通道注意力模块

在通道和平面上，通道注意力模块和空间注意力模块是互补的，是用于学习输入的特征快在特征平面上的空间关系。但是空间注意力模块注意的是特征平面上某块区域，而不是某个通道。在空间注意力模块中，首先对 $F^{'}$ 沿着通道进行最大池化 $F^{s}_{\max}$ 和平均池化操作 F^{s}_{avg}， 然后将两个特征连接起来，并通过标准卷积层进行卷积操作，在经过 sigmoid 激活函数，生成空间注意力图 M_s 。最后如式（3-14）所示，将和 F' 空间注意力图 M_s 相乘，便得到了具有注意力机制的特征图 F'' 。

$$M_s(F'') = \sigma(f^{7*7}([AvgPool(F'); MaxPool(F')]) \tag{3-14}$$

其中 F 表示在注意力模块中输入的特征， f^{7*7} 代表 7*7 的卷积操作。

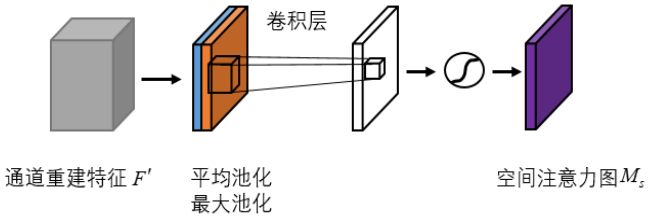

图 3-11　空间注意力模块

同时为了进一步防止随着网络的加深，底层信息的丢失，降低生成红外图像的质量，引入注意力模块后，得到图 3-12 所示的引入注意力模块后的生成器生成图像过程。这样能够使得生成器在生成图像时，更聚焦局部细节特征，充分分析图像本身的内部特征，提取主要特征，进一步减少整体改变以及局部错误映射，生成细节不足的问题。

中国知网　https://www.cnki.net

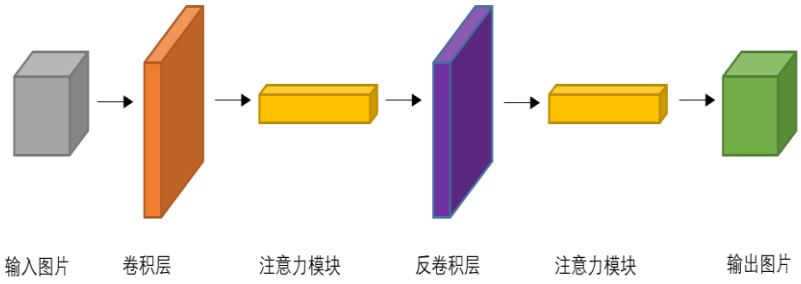

图 3-12　引入注意力模块后的生成器生成图像过程

3.3　实验结果与分析

3.3.1 数据处理与实验环境

（1）数据集介绍

在实际实验中，由于现有符合要求的非配对红外可见光数据的严重不足，同时为了得到更高质量的红外图像仿真结果，因此本文在实验中使用配对训练集作为网络的训练数据，需要 4000 组两个域的配对图像数据作为改进 CycleGAN 网络的训练集，100 组可见光与红外配对数据集作为测试集，由于实验中实拍红外图像数据不足，因此采用 800 组传统红外仿真软件 SE-Workbench-IR 生成的红外图像数据对，以及 1200 组实际拍摄的可见光图像数据以及红外图像数据对，之后对这 2000 组数据进行数据增强获得 4100 组数据。这 4100 组训练数据中，其中包括正午 12:00 时刻训练数据 3700 组，夜间 7:00 时刻数据 400 组，在实际训练中分别对正午 12:00 时刻训练集以及夜间 7:00 时刻两组训练数据集进行分别训练与测试。整个数据的图像包括建筑物、道路、草地、荒漠、树木、灌木丛、车辆等，图像的大小为 256×256 。

（2）网络参数设置与实验环境

训练过程中，本章 batchsize 设置为 1，共训练 20000 步，学习率设为 0.0002，使用 Adam 优化器，β_1、β_2 设置 0.5,0.999，本章实验环境如表 3-1 所示：

中国知网　https://www.cnki.net

表 3-1 实验环境

实验配置	型号和版本
操作系统	Linux Ubuntu16.04
CPU	Intel i7-6900K 3.2GHZ 8 core 16threads
GPU	NVIDIA GeForce GTX 1080Ti
内存	128G
TensorFlow	1.4
CuDNN	9.0.176
Opencv	2.4.9

3.3.2 实验结果分析与讨论

对于本章改进 CycleGAN 网络仿真生成的红外图像，本节将从主观评价以及客观评价两个角度对仿真生成的红外图像进行评价。首先是主观评价角度，即通过人眼观察的方式直接对仿真生成的红外图像进行评价。

如图 3-13 所示的可见光图像、原始 CycleGAN 仿真生成的红外图像、改进 CycleGAN 仿真生成的红外图像，以及实拍的红外图像序列图。通过对序列图进行对比发现，前四组的实验结果由于正午 12:00 的训练集较多，原始 CycleGAN 网络能生成效果较好的红外图像，但是在部分红外图像中，出现过拟合现象，存在整体偏移，引入条纹噪声，以及局部细节刻画不够，且出现错误映射的情况。改进后的 CycleGAN 网络生成的红外图像具有较高的有效性，整体质量差问题得到改善，错误映射情况也得到了改善，在细节刻画上有所提升，对生成红外图像失真情况得到一定程度的改善，能够在一定程度上满足实际工程需求，尤其图中，最后一组对夜间场景进行红外图像仿真，由于夜间场景 7:00 的训练数据集较少，使用原始 CycleGAN 网络生成的红外图像，失真较为严重，而改进后的网络生成效果有了很大程度提升。

中国知网 https://www.cnki.net

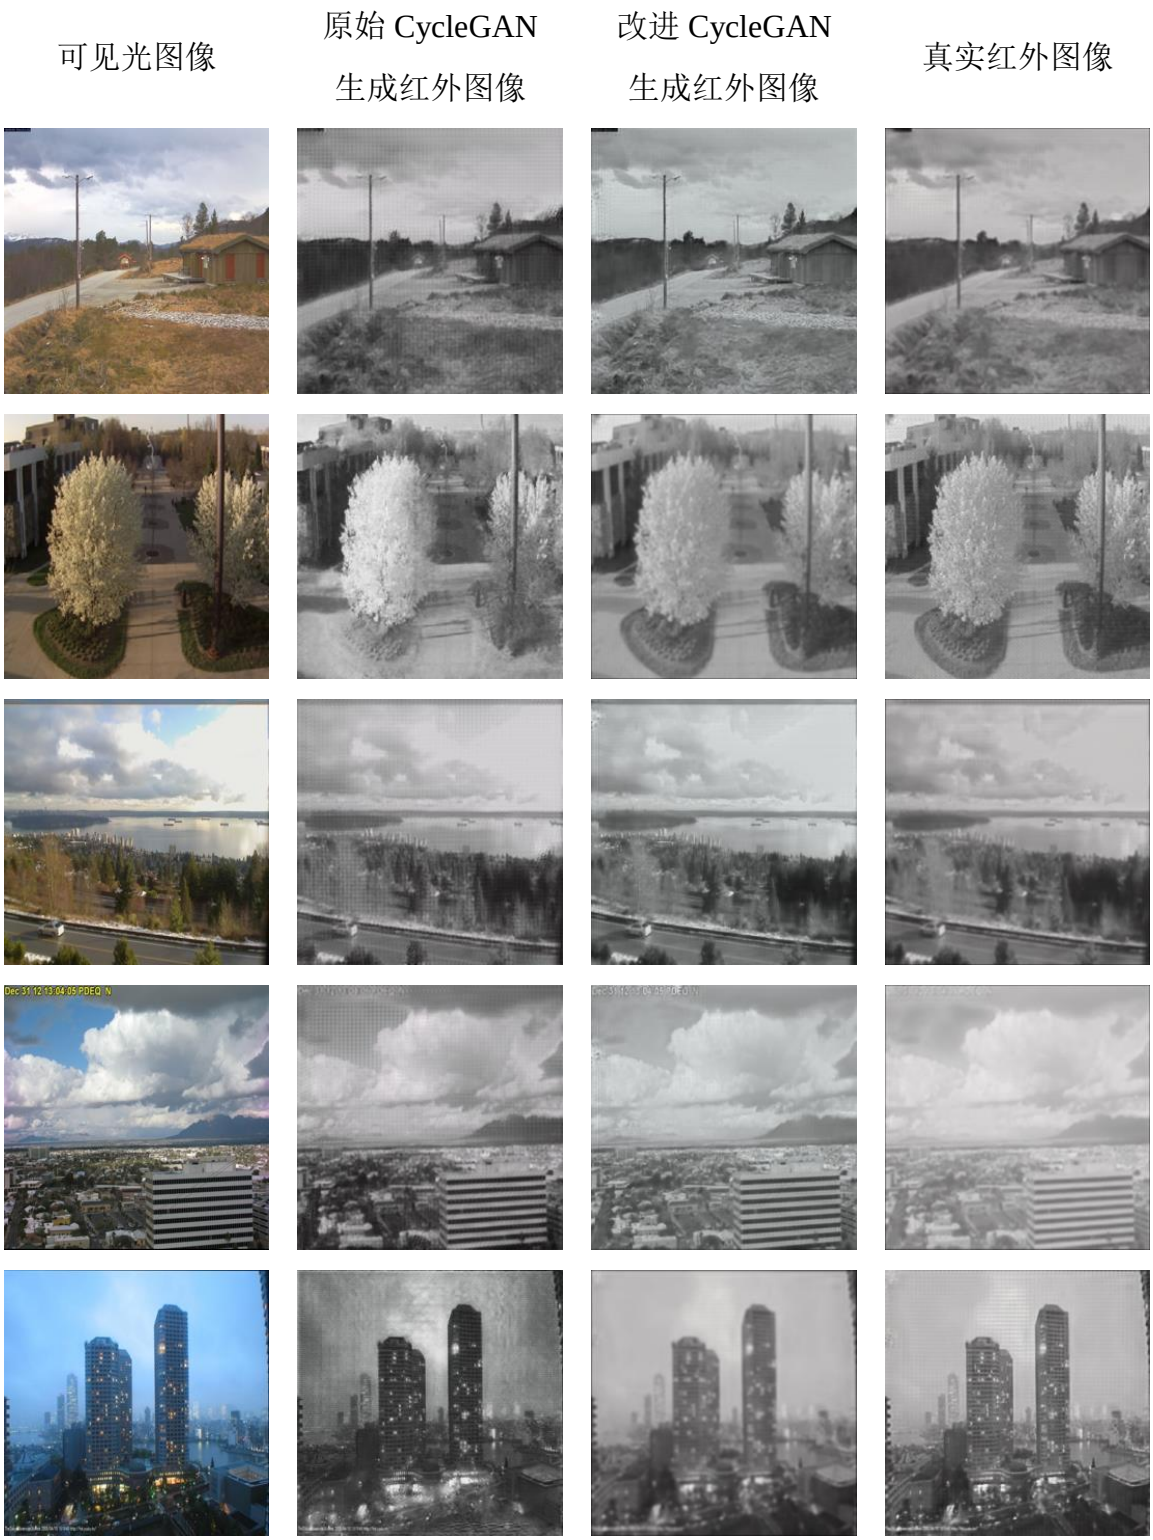

图 3-13　CycleGAN 网络改进前后生成红外图像序列图

中国知网　https://www.cnki.net

人眼主观对仿真生成的红外图像进行评价，往往并不够严谨，很难较为真实全面的对仿真生成的红外图像进行评价，因此下文将从具体评价指标角度对生成红外图像进行客观评价。本文将通过对仿真生成的红外图像与实拍的红外图像直接进行客观参数比较，通过比较两者的差距来判断本章方法生成红外图像的质量。为了进一步验证本章提出的方法生成的红外图像的有效性与可用性，本节将从 PSNR、SSIM 两个评价指标对仿真生成的红外图像进行评价，同时还将从仿真生成红外图像对应材质的灰度特性，以及仿真生成红外图像在实际目标检测领域的作用三个角度进行实验分析与论证。

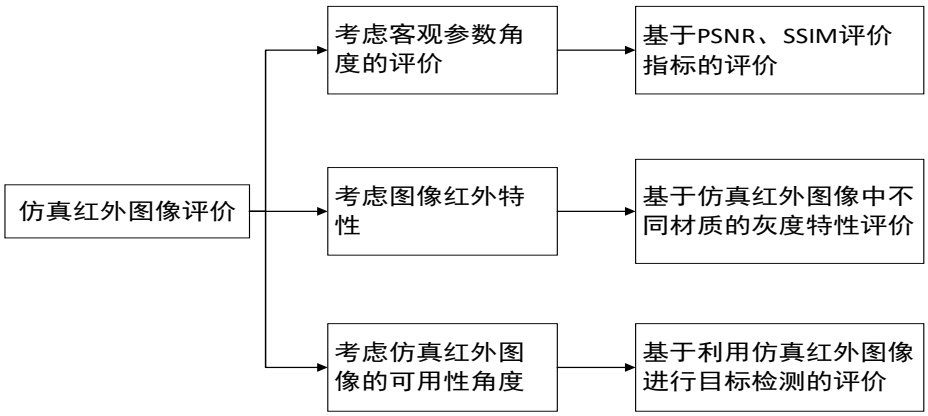

图 3-14　仿真生成红外图像客观评价体系

(1) 基于客观参数的评价

为了进一步说明本章改进 CycleGAN 网络仿真生成红外图像的质量，本节针对原始 CycleGAN 网络生成结果以及改进后 CycleGAN 网络结构生成红外图像分别与真实红外图像进行 PSNR、SSIM 两个评价指标对比。

在本节，选取图 3-13 中前两组真实红外图像，原始 CycleGAN 网络仿真生成红外图像以及本章改进 CycleGAN 网络仿真生成红外图像，使用 PSNR、SSIM 评价指标进行客观角度比较。本章对使用原始 CycleGAN 网络以及改进后 CycleGAN 网络仿真生成的红外图像，分别与真实红外图像进行比较，得到对图 3-15 乡村场景进行基于 PSNR、SSIM 的成像质量评价，得到的表 3-2 所示的结果，以及对图 3-16 公园场景进行基于 PSNR、SSIM 的成像质量评价，得到的表 3-3 所示的结果，通过比较发现改进后的 CycleGAN 网络仿真生成的乡村场景红外图像，以及公园场景红外图

中国知网 https://www.cnki.net

像，与对应的实拍乡村场景红外图像，公园场景红外图像，其计算的 PSNR、SSIM 值都比原始 CycleGAN 网络仿真生成的结果，有了一定程度的提升。

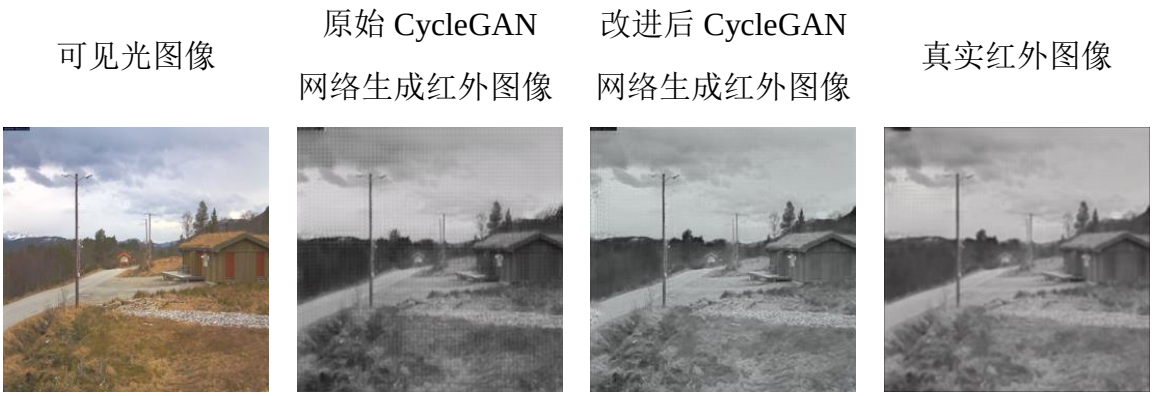

图 3-15　乡村场景

表 3-2　乡村场景仿真红外图像与实拍红外图像的 PSNR、SSIM 评价

	PSNR（dB）	SSIM
原始 CycleGAN 网络生成红外图像	24.56	0.8989
改进后 CycleGAN 网络生成红外图像	30.5209	0.9138

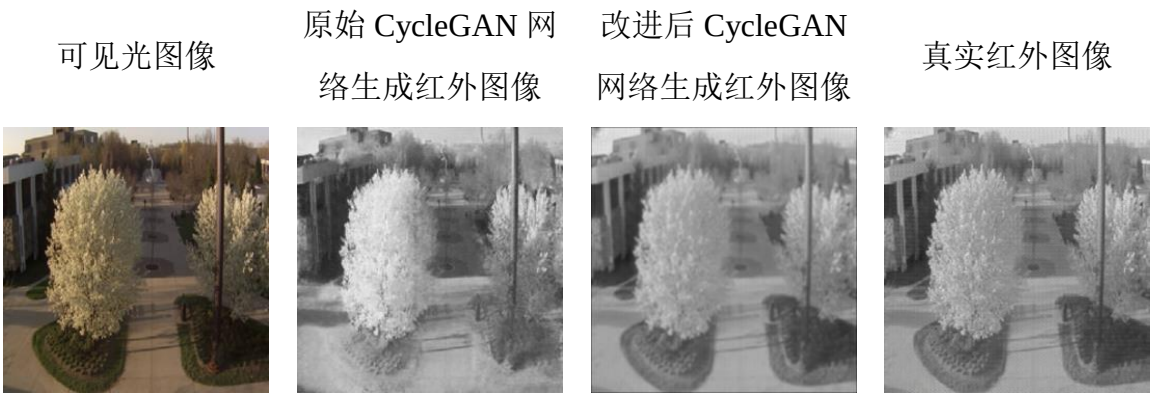

图 3-16　公园场景

中国知网　https://www.cnki.net

表 3-3　公园场景仿真红外图像与实拍红外图像的 PSNR、SSIM 评价

	PSNR(dB)	SSIM
原始 CycleGAN 网络生成红外图像	20.54	0.7471
改进后 CycleGAN 网络生成红外图像	30.79	0.9083

为了验证本文在原始 CycleGAN 中增加抑制器网络 S、生成重建通路损失函数，以及注意力模块在网络中的作用，本节进行了表 3-4 的消融实验，在整个 100 张测试集上，不同方法生成的红外图像，与对应真实的红外图像的 PSNR,SSIM 值情况，同时为了防止单一图像实验结果的偶然性，本节计算 100 张测试图像的平均 PSNR、SSIM。实验对比发现，本章所引入的模块，对于生成图像的有效性上都有所贡献，其中抑制器 S 的引入对于提升生成图像的质量具有较大贡献。同时改进 CycleGAN 网络就够生成红外图，与真实红外图像之间 PSNR 较高、SSIM 值较大，说明两者仿真生成结果与实际红外图像的像素间差异较小，整体结构相似度较高。

表 3-4　本章各部分改进步骤消融实验

	平均 PSNR(dB)	平均 SSIM
原始 CycleGAN	26.59	0.7378
原始 CycleGAN+抑制器 S	28.86	0.7756
原始 CycleGAN+注意力模块	27.07	0.7474
原始 CycleGAN+抑制器 S+注意力模块	29.40	0.7813
原始 CycleGAN+抑制器 S+注意力模块+生成重建通路损失函数	29.74	0.7892

(2) 基于生成红外图像中材质的灰度直方图评价

红外图像可以使用灰度直方图表示其灰度分布，包括灰度的最大值、最小值，以及灰度主要集中分布在哪个区域的情况，同时灰度直方图能很好地反映出不同材

中国知网 https://www.cnki.net

质的红外特性情况。因此为了进一步衡量改进后 CycleGAN 网络结构仿真生成红外图像的质量，将对仿真生成红外图像材质的灰度特性进行比较，以及图 3-17 所示材质的灰度分布情况。

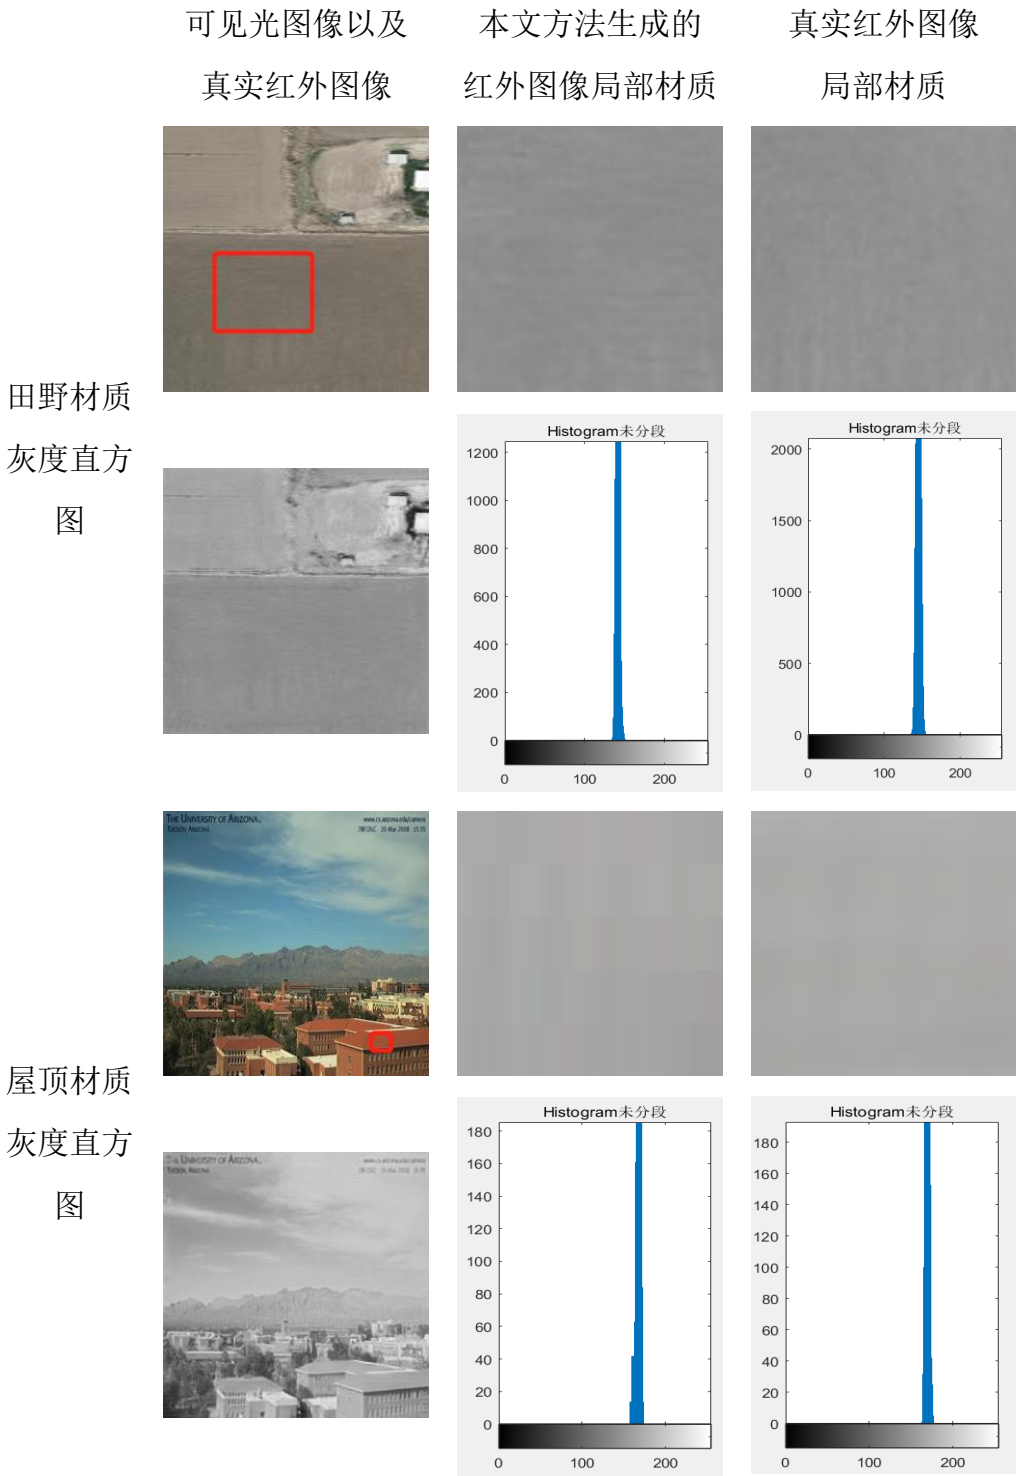

中国知网 https://www.cnki.net

道路材质灰度直方图

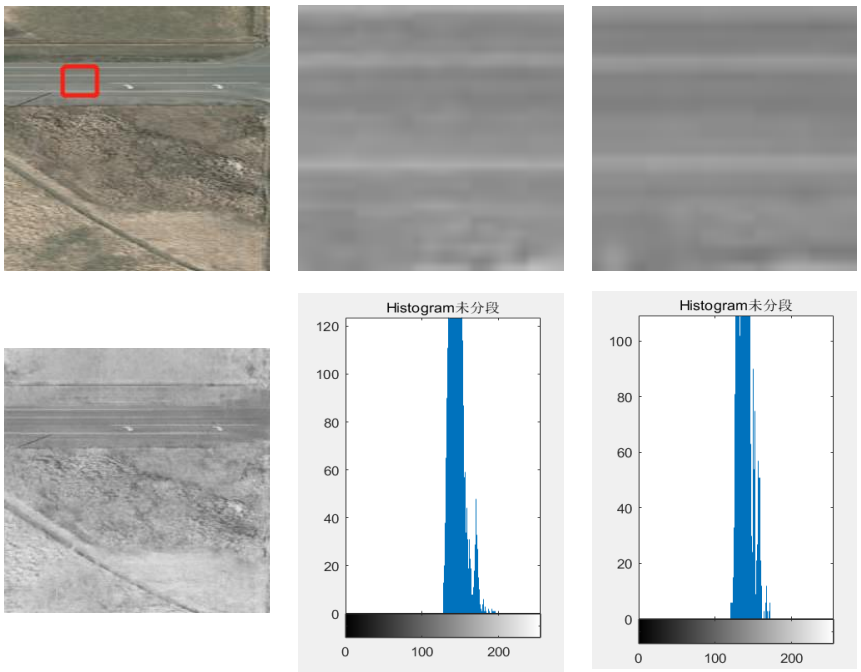

图 3-17　仿真红外图像与真实红外图像材质灰度直方图

通过图 3-17 所示，对比改进 CycleGAN 网络仿真红外图与真实红外图在田野材质、屋顶材质，以及道路材质的灰度直方图情况，本文改进 CycleGAN 网络方法仿真生成红外图像中的材质的灰度分布情况，与真实红外图像中同种材质的灰度分布，虽然仍然存在一定的区别，但是其灰度分布大体是一致的。此外本章还从红外目标检测的角度对仿真生成的红外图像进行了进一步的实验探究。

(3) 基于目标检测应用角度的评价

图 3-18　可见光机场图像转换为红外机场图像结果

本节从仿真生成红外图像的实际可用性角度，对仿真生成的红外数据进行实验探究。本章利用改进后的 CycleGAN 网络将可见光图像机场数据，转换为相应的红

中国知网 https://www.cnki.net

外图像数据，用于解决红外机场目标检测问题中，训练样本严重不足的问题，图 3-18 为将可见光机场转换为红外机场的结果。

为了验证本章方法仿真生成红外图像的可用性，本章选用 SSD 网络[57]模型为红外机场目标检测基本网络，在 SSD 网络的训练集上选择 900 张航拍红外机场作为目标检测网络的基础训练集，同时在 900 张原始红外机场数据机场上，分别设置两组对照实验，一组在训练数据集 900 张原始红外机场数据基础上，向 SSD 目标检测网络的训练集中继续直接增加可见光机场数据，另外一组在训练数据集 900 张原始红外机场数据基础上，向 SSD 目标检测网络的数据集中继续增加本章改进 CycleGAN 网络仿真生成的红外机场数据。

两组对比实验作为 SSD 网络的训练集，都分别从 0 张依次增加 200 张数据直到增加 1600 张为止，用于对比增加不同数量的可见光数据和本文改进 CycleGAN 仿真生成红外数据到 SSD 目标检测网络的训练集中，在小样本情况下的对红外目标检测的不同影响效果。同时考虑到检测网络的训练集数量较少，本实验在训练之前，都先将 SSD 网络在 ImageNet 数据集上进行预训练，达到对网络参数进行初始化的目的，之后再利用当前数据集进行继续训练。最后使用 100 张真实红外机场数据作为测试集，并得到表 3-5 所示实验结果，以及图 3-19 所示检测结果：

表 3-5　添加可见光图像数据和本文仿真生成红外图像数据对比实验

添加训练样本数量	添加可见光机场数据 (AP/%)	添加改进 CycleGAN 生成红外机场数据(AP/%)
0	75.6	75.6
200	75.9	76.1
400	76.2	76.6
600	76.8	77.3
800	77.5	78.1
1000	78.5	79.8
1200	79.0	79.9
1400	78.7	80.1
1600	78.4	80.1

中国知网 https://www.cnki.net

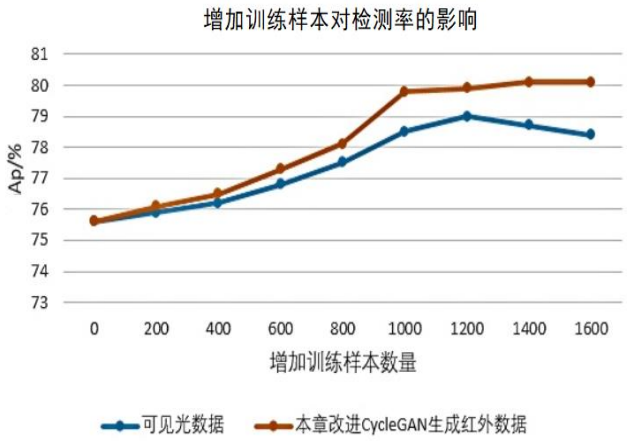

图 3-19　检测结果对比

通过图 3-20 发现，通过分别增加可见光数据以及本章方法仿真生成的红外数据到 SSD 目标检测网络的训练集中，都能在一定程度上提高红外机场目标的检测率，对于可见光数据集，当增加数据量较少时，随着数据的增加，检测率随之增加，但是当增加可见光数据量较大时，由于破坏了红外特性分布，检出率反而有所降低现象，而对于添加的本章方法仿真生成红外数据，随着训练样本的增加，检测率也随着增加。此外通过增加本章改进 CycleGAN 网络仿真生成的红外图像数据，明显比直接增加可见光图像数据，在 SSD 网络红外检测效果上有着显著的提升。

在目标检测中，当样本不足时，通常还采取复制，裁剪等常规方式对训练数据进行增强。本章继续探究使用常规数据增强方法与使用改进 CycleGAN 网络仿真生成新的红外图像进行数据增强对检测效果的影响，本节使用 900 张实拍红外机场数据作为训练集，同时分别在 900 张实拍红外机场数据中随机选择 400 张，对其分别进行以下四种方式进行数据增强：

复制；

仿射变换；

原始 CycleGAN 网络生成 400 张红外图像；

改进 CycleGAN 网络生成 400 张红外图像。

即分别通过四种不同数据增强方式，使得原训练样本增加到 1300 张，对比四种数据增强方法，对目标检测效果的影响，本次仍然使用 SSD 作为检测网络，100 张

中国知网　https://www.cnki.net

实拍机场红外数据作为测试集，并得到表 3-6 所示的不同数据增强方式，在目标检测效果上的效果对比。通过实验结果发现，在增加相同数量的训练样本的情况下，使用本章改进 CycleGAN 仿真生成的红外图像数据进行数据增强的方法，比常规数据增强方法，对于红外目标检测具有更好的效果。

表 3-6　不同数据增强方式对检测效果对比

数据增强方法	检测率(AP/%)
复制	75.9
仿射变换	76.0
原始 CycleGAN 生成数据	76.4
改进 CycleGAN 生成数据	76.6

同时为了进一步详细比较使用原始 CycleGAN 网络仿真生成的红外图像，与本章改进 CycleGAN 仿真生成的红外图像，在实际红外目标检测中的作用，本章在使用 900 张实拍红外图像为基础训练数据集的基础上，分别增加可见光数据集、原始 CycleGAN 仿真生成红外图像数据集、本章改进 CycleGAN 仿真生成红外数据集，到 SSD 目标检测网络的训练集中。选用 100 张实拍红外机场数据集作为测试机，并得到表 3-7 所示的改进前后 CycleGAN 仿真生成红外图像数据对目标检测的影响，以及图 3-20 所示检测结果。通过实验结果对比可以发现添加原始 CycleGAN 网络生成的红外场景数据到 SSD 网络的训练集中，能够比添加可见光数据到 SSD 训练集获得更好的检测效果，而添加改进后 CycleGAN 网络生成的红外图像数据能进一步提高检测效果。

中国知网 https://www.cnki.net

表 3-7　改进前后 CycleGAN 仿真生成红外图像数据对目标检测的影响

添加训练样本数量	添加可见光机场数据(AP/%)	添加原始 CycleGAN 生成的红外图像数据(AP/%)	添加本章改进 CycleGAN 生成的红外图像数据(AP/%)
0	75.6	75.6	75.6
200	75.9	76.1	76.1
400	76.2	76.4	76.6
600	76.8	77.1	77.3
800	77.5	77.7	78.1
1000	78.5	79.1	79.8
1200	79.0	79.4	79.9
1400	78.7	79.5	80.1
1600	78.4	79.5	80.1

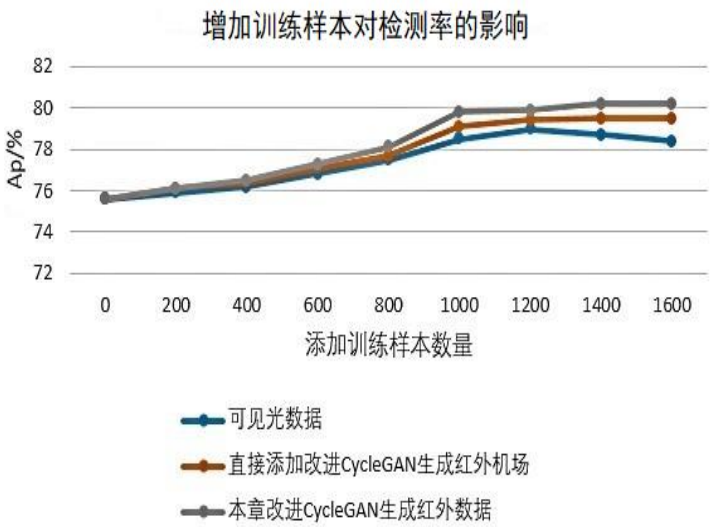

图 3-20　使用改进前后 CycleGAN 生成红外图像数据对目标检测的影响

3.4　本章小结

本章介绍了 CycleGAN 网络的具体网络结构以及损失函数，并对其进行红外图像生成过程中存在的不足进行分析，针对在原始 CycleGAN 网络结构进行红外图像

中国知网　https://www.cnki.net

仿真生成中存在的不足，本文提出了引入抑制器模块 S，防止生成过程中出现过拟合现象，减少整体质量差以及局部错误映射的出现。引入计算生成路径和重建路径损失函数可以减少由于两个生成器都进行错误映射现象情况的出现，同时在一定程度上提高网络训练过程的稳定性，添加注意力模块，改善卷积神经网络对图像细节特征关注不够，造成的仿真生成的红外图像容易遗漏细节特征的问题，提高生成的红外图像细节部分质量。针对本文方法仿真生成的红外图像，本章也进行了详细的评价，从 PSNR、SSIM 客观参数评价指标角度对改进 CycleGAN 网络生成的红外图像进行评价，同时将改进 CycleGAN 网络生成的红外图像中材质的灰度特性，与真实红外图像中材质的灰度特性进行比较。此外本章还从红外目标检测的角度，对本章改进 CycleGAN 网络方法仿真生成的红外图像的可用性进行了比较，进行了实验探究。综上，本章仿真生成的红外图像方法能一定程度提高生成红外图像的质量，同时本章方法仿真生成的红外图像数据在实际应用中，也具有一定的实际可使用性。

中国知网 https://www.cnki.net

4 基于改进 SRGAN 网络的红外图像超分辨率重建

第三章利用改进 CycleGAN 网络，能够仿真生成较好的红外图像数据，但是在实际使用时，由于此前所使用的红外成像器分辨率低、成像质量不高，利用该数据通过改进 CycleGAN 生成的部分红外图像也通常伴随着分辨率低的问题，即如图 4-1 所示 CycleGAN 生成的低分辨率红外图像，其图像较为模糊、分辨率低的情况，这会严重影响红外图像目标检测的效果。同时随着红外成像技术的发展，这些较低分辨率数据并不能直接用于现有较高分辨率下红外目标检测网络的训练工作，为了能在较高分辨率成像条件下，进行红外图像的检测识别任务，需要对仿真生成的红外图像进行超分辨率重建工作。以 SRGAN[51]网络为代表的深度学习方法能够取得比传统方法更好的图像进行超分辨重建效果，但是应用原始 SRGAN 网络进行红外图像进行超分辨率重建时存在对图像底层特征、以及图像的边缘纹理信息关注不够的问题。为此本章提出对 SRGAN 网络生成器的连接方式改进采用密集连接，同时对 SRGAN 网络的损失函数进行改进，从而获得更好的红外图像超分效果。

图 4-1　CycleGAN 生成的低分辨率红外图像

4.1 SRGAN 网络

4.1.1 SRGAN 网络结构

SRGAN 网络能够取到较好的红外图像进行超分辨率重建效果，其网络结构如图 4-2 所示：

中国知网 https://www.cnki.net

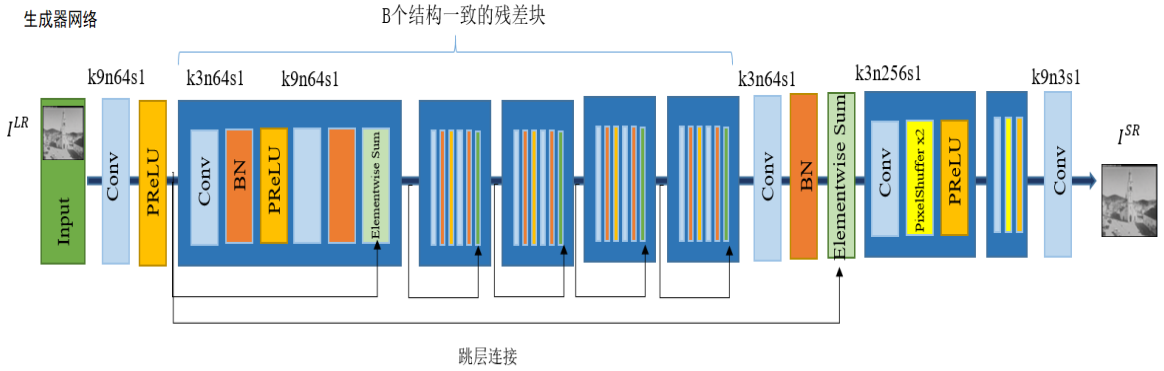

（a）生成器网络

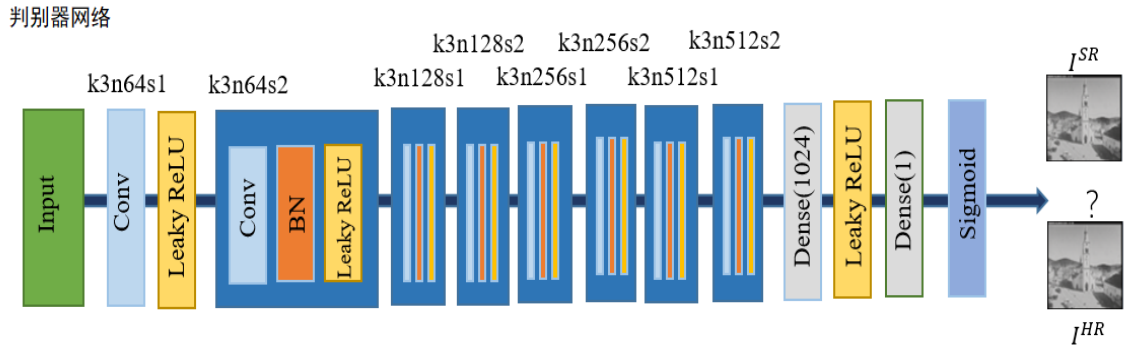

（b）判别器网络

图 4-2　SRGAN 网络模型结构

整个 SRGAN 网络生成器部分，由 15 个网络层构成，其中 k 表示卷积核的大小，n 表示卷积核的个数，s 表示卷积的步长。生成部分是基于残差网络结构设计，这种设计进一步加强了整个生成模型的学习能力，同时也减轻了网络在反向传播过程中的梯度消失的问题。SRGAN 网络生成器的前三层，为图像特征提取过程，中间网络为红外图像重建过程。对于输入的低分辨率图像，首先经过 64 个 9*9 的卷积层，然后再使用 PReLU 对其激活，再经过多个相同的（包括 1 个 $64\times3\times3$ 的卷积层，1 个 BN 层， PReLU 激活函数对其进行激活，1 个 $64\times3\times3$ 的卷积层，1 个 BN 层）残差块之后，把输出和残差块的输入进行叠加操作，作为下一残差块的输入，经过残差块操作后，再通过 9×9 的卷积和亚像素卷积层对齐进行上采样操作，重建出高分辨率的图像。

中国知网 https://www.cnki.net

SRGAN 网络的判别器部分中使用 LeakyReLU 激活函数来避免整个网络模型的最大池化，总共包括 10 个网络层，同样用 k 代表卷积核的大小，其中 n 表示卷积核的个数，s 表示步长。在判别器网络 D 中，使用类似 VGG19 的网络，但并未进行最大池化。输入的图像经过$64\times3\times3$的卷积层，Leaky ReLu, 每个卷积模块中卷积核的数量，按照从 64 个按 2 倍依次进行递增方式，直到 512 个，然后再通过一个密集层 Dense 层、以及 Leaky ReLu 激活函数，最后一次采用 Sigmoid 激活函数从而保证输出值在[0,1]之间，用以获取最终的样本分类概率。

4.1.2 SRGAN 中的损失函数

在 SRGAN 网络中对单幅图像进行超分处理时，目标是能够将输入的低分辨率图像I^{LR}，经过 SRGAN 网络模型后，生成相应的超分辨率图像I^{SR}。SRGAN 网络首先需要对I^{HR}图像降采样得到低分辨率图像I^{LR}，该降采样过程是降采样因子为 r 的高斯滤波器实现的。在对 C 个通道的图像，用张量大小为$rW*rH*C$、W*H*C 分别描述I^{HR}、I^{LR}。最终的希望是训练得到一个生成器网络 G，使得给定输入低分辨率图像，通过网络 G 后，可以生成对应的高分辨率图像，并对网络参数θ_G进行优化：

$$\hat{\theta}_G = \arg\min_{\theta_G} \frac{1}{N}(\sum_{n=1}^{N} l^{SR}(G_{\theta_G}(I_n^{LR}), I_n^{HR})) \qquad (4\text{-}1)$$

如果超分辨率重建中单纯使用 MSE 的 pixel-wise 方式，会导致生成的红外图像过于平滑。为此 SRGAN 网络设计了l^{SR}为感知损失函数。该损失函数先通过 VGG 网络提取图像的高级特征，然后使用 MSE 对这些高级特征进行处理，这样能更好的抓住不变特征信息。G 网络和 D 网络交替迭代，来优化式（4-2）所示 SRGAN 网络损失函数：

$$L_{SRGAN} = E_{I^{HR}\sim p_{train}(I^{HR})}[\log D(I^{HR})] + E_{I^{HR}\sim P_G(I^{LR})}[\log(1-D(G(I^{LR})))] \qquad (4\text{-}2)$$

公式（4-2）的思想是训练生成网络生成图像去欺骗判别器，然后判别器网络区分生成的高分辨率图像与真实高分辨率图像，这种训练方法可以促进网络学习重建出与高分辨率图像相似的图像，使得判别器网络难以区分，最终生成在感知方面更

中国知网 https://www.cnki.net

有优势的图像，训练生成器网络的目的是使得该式最小，而判别器网络的最终目标是使该式最大，因此整个训练过程就是生成网络和判别网络的博弈过程。

SRGAN 网络的损失函数由内容损失和对抗损失两部组成，最后再使用一定的权重对其进行相加。

$$l_{MSE}^{SR}=\frac{1}{r^2WH}\sum_{x=1}^{rW}\sum_{y=1}^{rH}(I_{x,y}^{HR}-G(I^{SR})_{x,y})^2 \tag{4-3}$$

1）内容损失函数：如式（4-3）所示内容损失函数，在该网络中，内容损失是用于计算基于均方差误差的损失函数。但在使用内容损失函数时，通过均方误差计算获取感知图像间的差异能力有限，使得最终虽然能够得到 PSNR 值较高的高分辨率图像，但生成的图像过于平滑，高频细节丢失。在实际使用时通常使用式（4-4）计算内容损失函数：

$$l_{VGG/i,j}^{SR}=\frac{1}{W_{i,j}H_{i,j}}\sum_{x=1}^{W_{i,j}}\sum_{y=1}^{H_{i,j}}(\phi_{i,j}(I^{HR})_{x,y}-\phi_{i,j}(G(I^{LR}))_{x,y})^2 \tag{4-4}$$

其中：$W_{i,j}$和$H_{i,j}$分别表示 VGG 网络中特征图谱维度，$\phi_{i,j}$表示 VGG-19 网络第 j 层卷积第 i 个最大池化层在前面获取到的特征图。

2）对抗损失函数：SRGAN 把生成器对感知损失的影响通过对抗损失表现出来。对抗损失函数使得 SRGAN 能够生成接近高分辨率的图像。SRGAN 把通常对抗损失换成式（4-5）所示，负对数求和的函数，从而获得更好的梯度特征：

$$l_{Gen}^{SR}=\sum_{n=1}^{N}-\log D(G(I^{LR})) \tag{4-5}$$

其中，$D(G(I^{LR}))$ 表示 SRGAN 网络中 D 网络，把 G 所生成的图像判别为真实高分辨率图像的概率，最终 SRGAN 模型中生成器函数表达式为：

$$l^{SR}=l_{Content}^{SR}+10^{-3}\times l_{Gen}^{SR} \tag{4-6}$$

4.1.3 原始 SRGAN 网络的缺点

原始 SRGAN 在进行红外图像进行超分辨率工作，已经能够得到如图 4-3 所示原始 SRGAN 网络对建筑物、海边、工业区的红外图像进行超分辨率结果。通过图中可以看出，利用原始 SRGAN 网络进行红外图像进行超分辨率重建结果，该方法在

中国知网 https://www.cnki.net

一定程度上提升了输入的低分辨率红外图像的质量，但是提升结果仍然不是很理想，尤其对于轮廓信息、纹理信息等提升并不是很理想。造成这种现象的可能原因是原始 SRGAN 网络使用 ResNet 连接方式，对图像的底层特征关注度还是不够，同时原始 SRGAN 中并没有对图像的边缘轮廓梯度信息进行额外关注。针对原始 SRGAN 网络使用 ResNet 连接方式，对图像的底层特征关注度还是不够问题，本章提出对原始 SRGAN 网络的生成器结果进行改进，将生成器中的残差模块部分改为 DenseNet 的密集连接方式，针对原始 SRGAN 中并没有对图像的边缘轮廓梯度信息进行额外关注问题，本章提出对原始 SRGAN 损失函数进行改进，增加一项边缘损失函数项，用于计算图像求梯度后超分辨率重建的损失。

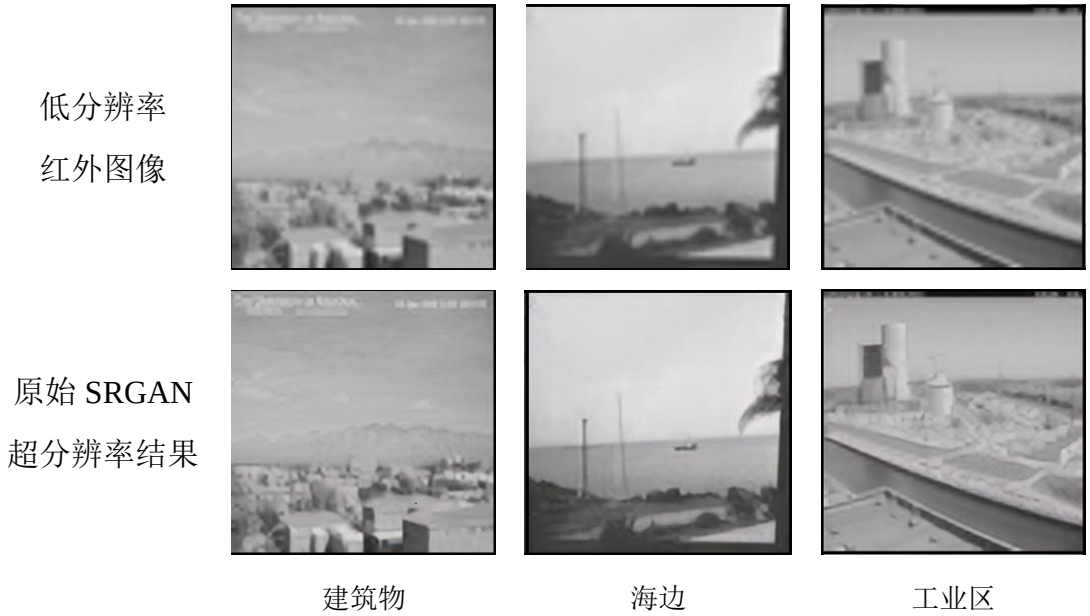

图 4-3　原始 SRGAN 超分辨率重建结果

4.2　SRGAN 网络改进

4.2.1 基于密集连接的 SRGAN 网络改进

通过对原始 SRGAN 网络进行红外图像超分辨率重建的不足分析可知，通过对深度学习网络模型层数的不断加深，虽然网络的拟合能力得到的提高，但是当神经随着网络层次的不断加深，图像底层的轮廓纹理信息会被丢失，而在红外图像中，

中国知网　https://www.cnki.net

图像的纹理和边缘轮廓信息恰恰是最重要的。此外随着网络深度的不断加深网络的训练难度也将逐渐增加，甚至最终会出现梯度弥散以及梯度爆炸等情况。为此本章借鉴 DenseNet 网络结构，对 SRGAN 进行改进，将 SRGAN 网络结构的残差链接方式改进为密集链接方式。

在实践中，卷积神经网络为了达到更好的拟合能力，通常会采取加深网络深度，或者加宽网络宽度的操作。DenseNet[52]从网络训练的 feature 入手，对 feature 学习，DenseNet 需要更少的参数便可以达到比较好的效果，同时由于该网络改变了梯度传播方式，减少了梯度消失的可能，加速了网络训练，并且具有在小数据集上能更好避免过拟合的能力，DenseNet 网络结构如图 4-4 所示：

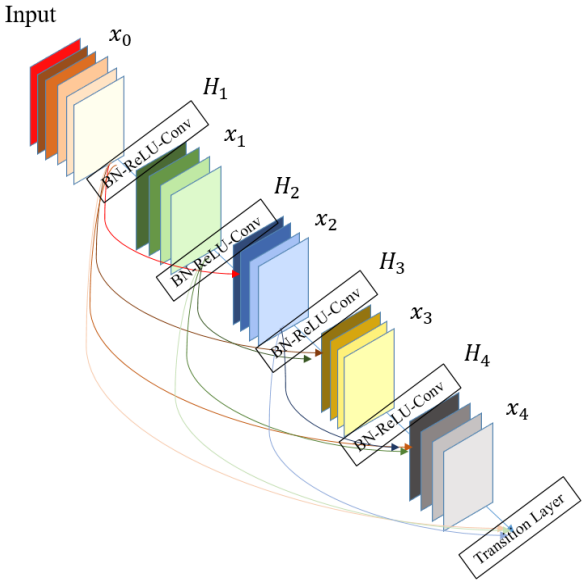

图 4-4　DenseNet 网络结构

通常网络结构中，对于输入的图像 x_0 定义一个 L 层的网络，$H_l(\bullet)$ 表示对他的第 l 层进行非线性变换，则有式（4-7）所示：

$$x_l = H_l(x_{l-1}) \tag{4-7}$$

在 ResNet 的残差结构网络中：

$$x_l = H_l(x_{l-1}) + x_{l-1} \tag{4-8}$$

中国知网　https://www.cnki.net

但是 DenseNet 网络并不是像残差网络一样进行简单的求和，而是从图像的特征入手，前面的提取到的特征放入到新的通道里，然后进行非线性操作，达到更好效果与并可以使用更少参数：

$$x_l = H_l([x_0, x_1, ..., x_{l-1}]) \tag{4-9}$$

因此对于 SRGAN 模块，本章参考 DenseNet 结构，对 SRGAN 的生成器网络结构进行改造，采用密集链接方式，同时不使用 bottleneck layer 层的 1*1 的卷积操作，得到图 4-5 所示基于 DenseNet 连接方式的 SRGAN 网络结构：

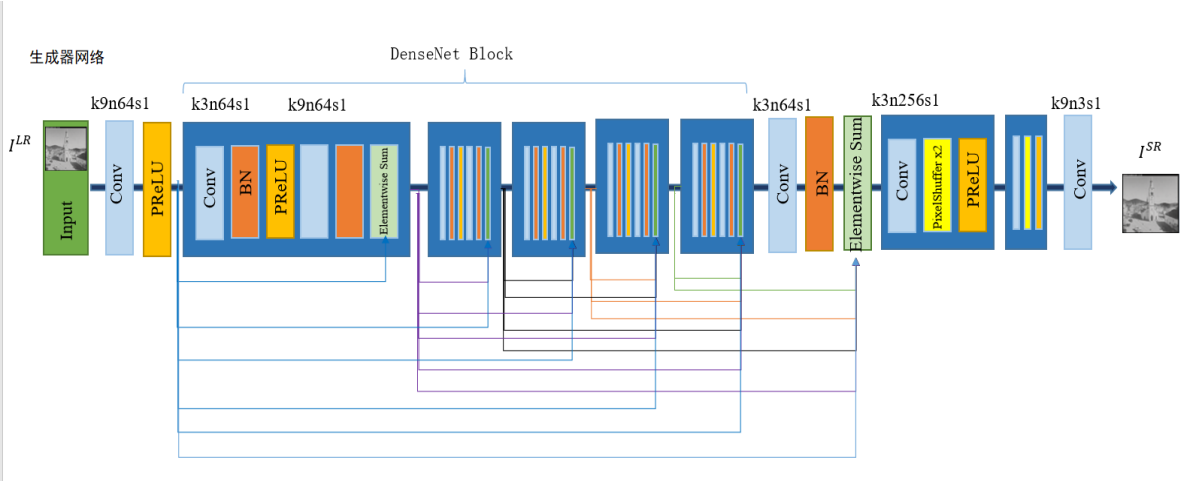

图 4-5　基于 DenseNet 连接方式的 SRGAN 网络结构

原始 SRGAN 网络的生成器部分使用 ResNet 连接方式，虽然在一定程度上加强了对特征的关注度，但是这种关注程度还是不够，在网络传递特征过程中，还是会存在对底层特征丢失的现象，从而造成超分辨率重建出的红外图像，在纹理细节上超分效果并不是很好。而使用 DenseNet 密集链接方式改进的 SRGAN 的生成器网络，可以将底层网络特征信息传播到整个生成器网络中，使生成器网络能更有效地学习纹理、边缘底层特征，可以更加有效地对难以识别、模糊、低质量的红外图像进行超分辨率重建工作，同时还可以解决在网络层数较深的情况下，出现梯度消失的问题，也有助于网络的反向传播，加快网络的训练过程。

在神经网络传输特征过程中，BN[59]层以 Batch 为单位，对图像的特征均值以及均方差进行归一化操作，使其归一化到一定范围，这样能够大大加快训练速度同时提升分类网络的分类效果，同时还能够降低网络对参数初始化的敏感程度。但是在

中国知网 https://www.cnki.net

对红外图像进行超分辨率重建过程中，BN 并不是很有效。Bee Lim 等人[58]在提出的 EDSR 超分辨率网络中，将 Resnet 的 BN 层去掉，一定程度上提升了超分辨率重建结果的 PSNR 值。

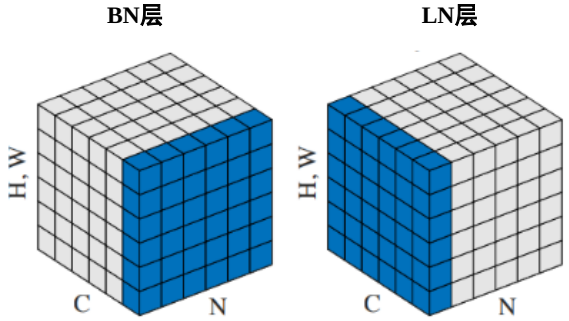

图 4-6　BN、LN 示意图[59]

本文在实际使用时，借鉴该方法了 Lim 直接去掉 BN 层的方法，但是本章在实际实验中发现将标准残差块中的 BN 层替换为 LN 层，比直接去掉 BN 层能获得更好的实验效果，即得到图 4-7 所示将 BN 层换成 LN 层的残差块前后对比图。BN 的计算就是把每个通道的 NHW 单独拿出来归一化处理，针对每个 channel 都有一组 γ和β，当 batch size 越小，BN 的表现越不好。LN 的计算就是把每个 CHW 单独拿出来归一化处理，不受 batchsize 的影响。

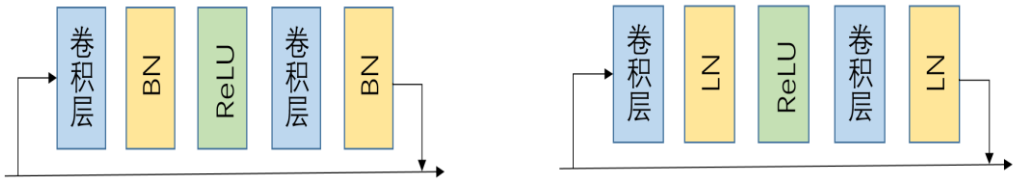

图 4-7　BN 层换成 LN 层残差块前后对比

为了验证本章将 BN 层换成 LN 层的作用，本章对比了在 SRGAN 中分别使用 BN 层和 LN 层，进行图像超分辨率重建的结果对比，下表列处了在 SRGAN 操作中分别 BN 层和 LN 层对超分辨率重建结果的影响。

中国知网　https://www.cnki.net

表 4-1　BN 层和 LN 层对图像超分辨率的影响

	PSNR(dB)	SSIM
LN 层	25.27	0.8332
BN 层	25.18	0.8314

4.2.2 损失函数改进

在红外图像中，图像的边缘信息、纹理信息都具有极为重要的意义，因此希望生成的高分辨率几何纹理清晰、突出的红外图像。红外图像的纹理信息与其边缘梯度信息有着密切的关系，通过对梯度进行计算，图像的边缘和纹理也会更加明显。因此在 SRGAN 网络中引入梯度损失，对于提高生成图像的质量，具有很好的作用。

在常见的用于计算图像梯度的算子中，二阶 Laplacian 算子由于具有 Laplacian 算子能够结合高斯滤波，对红外图像进行去噪，同时具有各向同性，具有更强的定位、锐化能力，可以对任何走向的界限和线条进行锐化的特点。对于二维图像 $f(i,j)$，Laplacian 算子如式（4-10）所示，利用 Laplacian 算子对红外图像提取边缘结果如图 4-8 所示：

$$\nabla^2 f = f(x+1,y)+f(x-1,y)+f(x,y+1)+f(x,y-1)-4f(x,y) \tag{4-10}$$

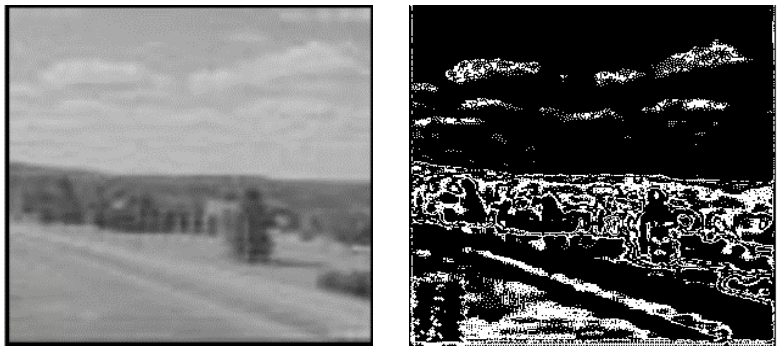

图 4-8　Laplacian 算子提取红外图像边缘结果

本文在 SRGAN 网络的生成器中加入边缘损失，从而可以使得生成器学习到图像的边缘纹理特征。经过训练后，改进 SRGAN 网络能够充分学习到高清图像的边缘特征，这样 LR 图像可以超分重建出几何纹理清晰、突出的 HR 图像。由于卷积运算是满足结合定律的，因此可以通过先将 Laplacian 算子和高斯滤波器进行卷积操作，然后再把低分辨率图像和该结果进行卷积，同时在对图像处理过程只有一个卷积运

中国知网 https://www.cnki.net

算，这样不仅可以减少运算量，还能提高运算的速度。本文将高斯滤波器和 Laplacian 算子相结合，生成 SR 和 HR 图像的梯度，能有效减少其对噪声的敏感性。

此时 SRGAN 的损失函数包括对抗损失，内容损失以及通过 Laplacian 算子计算的边缘损失梯度 （Edge Loss， E_loss ），边缘损失函数 E_loss 公式如下：

$$E_\text{loss} = \frac{1}{W_{i,j}H_{i,j}} \sum_{x=1}^{W_{i,j}} \sum_{y=1}^{H_{i,j}} (\phi_{1i,j}(I^{HR})_{x,y} - \phi_{1i,j}(G(I^{LR}))_{x,y})^2 \qquad (4\text{-}11)$$

其中：

$\phi_{1i,j}$ 是对 $G(I^{LR})$ 和 HR 图像进行 Laplacian 操作得到的边缘特征图，$W_{i,j}$和$H_{i,j}$ 表示边缘图中不同通道的特征图，最终增加边缘梯度信息的损失函数后，SRGAN 超分辨率重建网络总的损失函数为：

$$l^{SR} = l_{Content}^{SR} + 10^{-3} \times l_{Gen}^{SR} + 10^{-1} \times E_\text{loss} \qquad (4\text{-}12)$$

其中：

l^{SR} 为 SRGAN 生成器损失函数，E_loss 表示本章增加的用于计算边缘的损失函数，$l_{Content}^{SR}$ 表示内容损失函数，l_{Gen}^{SR} 表示对抗损失函数。

4.3 实验结果与分析

4.3.1 数据处理与实验环境

（1）数据集介绍

本章研究应用改进 SRGAN 网络，能够多角度提升重建出的红外图像的质量。本章在进行改进 SRGAN 网络训练时，先在 ImageNet 数据集中，选取其中包含丰富纹理、边缘清晰且平滑区域较少的图片，作为本章实验的部分训练数据集，先对改进 SRGAN 网络模型进行预训练工作。之后再选择 500 张实拍分辨率较高的红外图像，同时由于实拍清晰地红外图像数据较难获取，因此又从第三章改进 CycleGAN 方法生成的红外图像中，挑选 500 张质量较高、分辨率较高的红外图像，得到共 1000 张红外清晰数据，对这 1000 张红外图像数据进行 4 倍降采样，得到 1000 组红外清晰以及红外模糊图像对，并采用数据增强技术，将每对红外图像分别进行 90^0、180^0、270^0 旋转进行数据增强，这样就可以得到 4000 组红外图像对，该数据集主

中国知网 https://www.cnki.net

要为场景较为规则的城市建筑物以及工业区场景。之后使用这 4000 组高分辨率与低分辨率红外图像对数据集，对改进 SRGAN 网络模型进行进一步训练网络，同时本章对照试验 ESPCN 网络的图像超分辨率实验同样在该数据集下进行训练。

（2）网络参数设置与实验环境

本文实验 batchsize 大小设为 4，总共训练 140000 步，学习率设置为 0.0002 。实验采用 Adam 优化器来对改进 SRGAN 网络的目标函数进行优化， β_1，β_2 分别设置为 0.5, 0.999，本章实验环境如表 4-2 所示：

表 4-2　本章实验环境

实验配置	型号和版本
操作系统	Linux Ubuntu16.04
CPU	Intel i7-6900K 3.2GHZ 8 core 16threads
GPU	NVIDIA GeForce GTX 1080Ti
内存	128G
TensorFlow	1.4
CuDNN	9.0.176
Opencv	2.4.9

4.3.2 实验结果分析

图 4-9 所示为使用 Bicubic 方法、ESPCN 网络、原始 SRGAN 网络以及改进后 SRGAN 网络不同方法，对 LR 低分辨率红外图像进行 4 倍超分辨率结果对比。通过实验结果图 4-9 对比发现，ESPCN 网络超分辨率重建的红外图像，其分辨率从直观感觉角度是有一定提高，但是提高的幅度有限，原始的 SRGAN 网络结构对 LR 红外图像进行超分辨率重建的结果，直观感觉具有不错的超分辨率重建效果，但是在部分红外图像超分辨率重建的结果中，对于红外图像比较关注的轮廓纹理等细节重建程度不够，本章提出的改进超分辨率重建方法对图像的轮廓纹理信息重建效果较好，同时红外图像整体超分辨率重建不错，相较原始 SRGAN 都有了一定的提高。同时通过图 4-9 发现在（b）工业区、（c）学校、（e）教堂这种场景较为简单规则的图

中国知网 https://www.cnki.net

像，网络的超分效果会更好一些，这里考虑原因是本次实验的训练集多为场景较为简单且规则的图像，同时改进 SRGAN 网络引入的边缘损失能更好的利用规则物体的边缘信息。为了能够更好地评价改进方法对实验效果的提升，因此还需要对图 4-9 的实验结果，通过表 4-3 进行 PSNR、SSIM 客观参数的评价。

Bicubic 超分红外图像	ESPCN 超分红外图像	原始 SRGAN 超分红外图像	改进 SRGAN 超分红外图像	目标 HR 红外图像

(a)城市

(b)工业区

(c)学校

(d)山区

中国知网 https://www.cnki.net

(e)教堂

图 4-9　不同方法 4 倍超分辨率重建结果对比

下面将通过 PSNR、SSIM 两个指标对图 4-9 中的实验结果（a）城市、（b）工业区、（c）学校、（d）山区、（e）教堂五组实验结果进行客观角度评价，并得到表 4-3 所示客观参数评价结果，其中 PSNR 以及 SSIM 最大的结果使用黑体进行加粗表示。

表 4-3　客观参数评价结果

	Bicubic	ESPCN	原始 SRGAN	改进 SRGAN	Bicubic	ESPCN	原始 SRGAN	改进 SRGAN
	PSNR（dB）				SSIM			
图像(a) 城市	21.25	22.17	21.72	**22.33**	0.7832	0.7945	0.7799	**0.8046**
图像(b) 工业区	24.83	25.28	24.52	**26.52**	0.8074	0.8460	0.8292	**0.8607**
图像(c) 学校	24.59	**26.40**	25.63	26.04	0.7719	**0.7953**	0.7828	0.7925
图像(d) 山区	22.40	**23.13**	22.50	22.85	0.7924	0.8069	0.7903	**0.8085**
图像(e) 教堂	24.13	25.57	25.19	**26.21**	0.8453	0.8504	0.8580	**0.8792**

通过表 4-3 结果对比发现，改进 SRGAN 网络对红外图像进行超分辨率重建的结果，其 PSNR 值以及 SSIM 值都比原始 SRGAN 网络有所提高，尤其是对于诸如（b）工业区、（e）教堂等场景较为简单规则的红外图像，改进 SRGAN 提升的效果更加

中国知网　https://www.cnki.net

明显，这里主要考虑到是由于本章引入边缘损失函数，对于较为简单的场景，能够获得更好的超分辨率重建效果。同时对于（a）城市以及（d）山区这种场景较为复杂包含细节较多的情况中，出现原始 SRGAN 网络超分辨率重建的 SSIM 值比 Bicubic 低的情况，这里考虑到该实验在进行中能够用于训练的红外场景数据较少，同时整个训练数据整体为较为规则简单的场景，未能很好的实现对场景较为复杂且包含细节较多的图像进行超分辨率重建，同时由于 SRGAN 中引入的感知损失函数的作用，使得超分辨率重建的结果也是更加倾向于生成符合人感知的结果。

表 4-3 中 ESPCN 网络计算得到 PSNR 值以及 SSIM 值都比原始 SRGAN 网络的要高，即使是对于本章改进的 SRGAN 网络，虽然在一定程度上提高了原始 SRGAN 网络结果的 PSNR、SSIM 值，但是在（c）学校以及（d）山区图像中的实验结果也要比 ESPCN 网络的计算值要低，这里主要是由于 ESPCN 网络是以 PSNR、SSIM 等计算值为导向的，更倾向于生成缺少高频细节信息并且平滑的重建高分辨率图像，而 SRGAN 由于映入了感知损失的缘故，生成更加符合人感知的实验结果。

为了具体说明这一问题，下面选取图 4-9 中（b）工业区以及（c）学校的超分辨率重建结果，进行 SEPCN 网络、原始 SRGAN 网络、改进 SRGAN 网络不同方法超分辨率结果局部细节的对比。并得到图 4-10 所示不同方法超分辨率结果的局部细节对比图。 结合图 4-10 以及表 4-3 中（b）工业区、（c）学校超分辨率重建结果的 PSNR、SSIM 计算值，可以发现使用 ESPCN 网络结果的 PSNR 值比原始 SRGAN 网络的要高，在表 4-3 中（c）学校图像 ESPCN 网络超分辨率重建的结果，要比原始 SRGAN 网络以及改进 SRGAN 网络的计算结果要好，但是在图 4-10 不同方法超分辨率结果的局部细节对比图中，原始 SRGAN 网络以及改进后 SRGAN 超分重建的细节较好，同时由于改进 SRGAN 网络进行密集连接改进以及引入边缘损失函数的缘故，对于规则物体的超分辨率重建效果也更好，而 ESPCN 网络超分辨率重建实验结果的局部细节图像并不是很理想。

中国知网 https://www.cnki.net

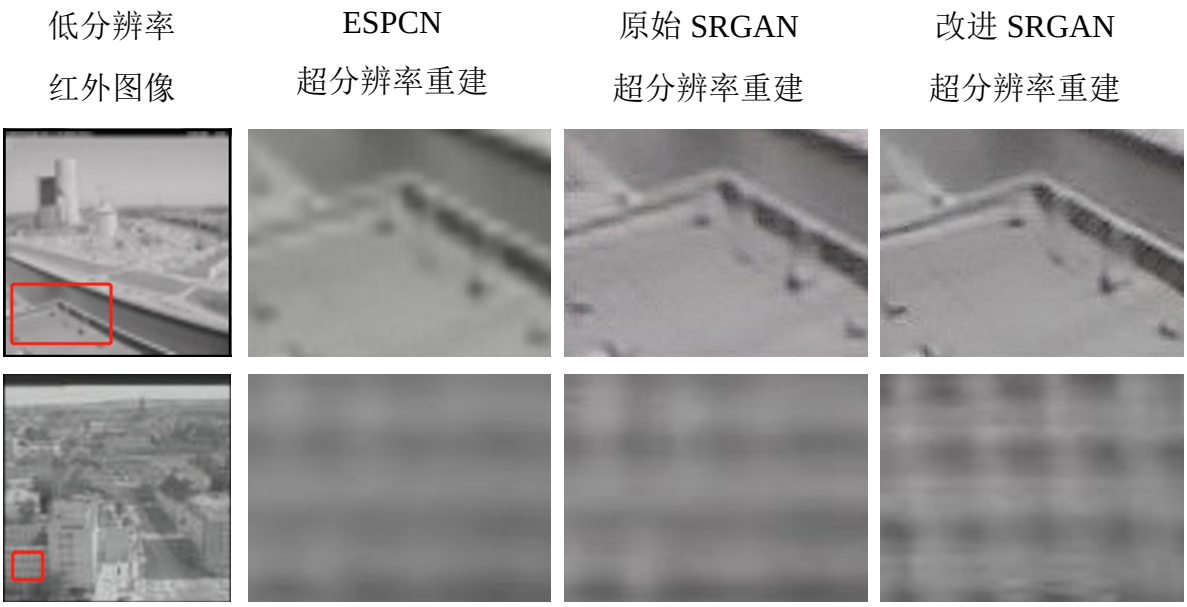

图 4-10　不同方法超分辨率结果的局部细节对比图

上述对单张图像进行不同方法超分辨率重建结果的分析，容易出现偶然性，为了更好对各种方法实验结果进行比较，避免这种偶然性，通常采取计算测试集的平均 PSNR、SSIM 值的情况。下面将使用 Bicubic、ESPCN 网络、原始 SRGAN 网络以及改进后 SRGAN 网络不同超分辨率方法，对图像进行×2、×4、×8 不同放大倍数情况的实验，并计算测试集上的平均 PSNR 以及 SSIM 值情况。并得到表 4-4 不同方法 2 倍超分辨率重建结果，表 4-5 不同方法 4 倍超分辨率重建结果，以及表 4-6 不同方法 8 倍超分辨率重建结果。其中计算的 PSNR、SSIM 最大值使用黑体加粗进行表示，第二大值使用下划线进行表示。

表 4-4 不同方法 2 倍超分辨率重建结果

Method	Scale	平均 PSNR(dB)	平均 SSIM
Bicubic	×2	26.86	0.8503
ESPCN 网络	×2	**28.94**	<u>0.8757</u>
原始 SRGAN 网络	×2	28.45	0.8749
改进后 SRGAN 网络	×2	<u>28.83</u>	**0.8812**

中国知网 https://www.cnki.net

表 4-5 不同方法 4 倍超分辨率重建结果

Method	Scale	平均 PSNR(dB)	平均 SSIM
Bicubic	×4	23.83	0.8094
ESPCN	×4	**25.31**	0.8275
原始 SRGAN	×4	24.89	0.8217
改进后 SRGAN	×4	25.27	**0.8332**

表 4-6 不同方法 8 倍超分辨率重建结果

Method	Scale	平均 PSNR(dB)	平均 SSIM
Bicubic	×8	20.57	0.6671
ESPCN	×8	**21.18**	**0.6803**
原始 SRGAN	×8	20.82	0.6772
改进后 SRGAN	×8	21.03	0.6786

通过对比表 4-4、4-5、4-6 的实验结果发现改进后 SRGAN 在×2、×4、×8 不同放大倍数情况下，超分辨率的实验结果的 PSNR 值以及 SSIM 值都比原始 SRGAN 网络的结果有所提高。在表 4-4 以及表 4-5 中进行×2、×4 放大倍数实验结果中， ESPCN 方法得到的实验结果 PSNR 都是最大的，而改进后 SRGAN 网络得到实验结果 PSNR 是第二大的，SSIM 是最大的，这里原因同样是由于 ESPCN 网络是依靠 PSNR、SSIM 等进行驱动的，而 SRGAN 引入了感知损失，使得超分辨率重建的结果更加符合人的感知，同时由于改进 SRGAN 中密集连接以及损失函数的改进，在本实验测试集多规则简单场景的图像中能够更好的保持图像的结构相似，在 SSIM 值上取得更好的实验结果。但是在表 4-6 进行×8 放大倍数实验时，由于训练集在进行 8 倍下采样过程中会丢失大量信息，此时改进 SRGAN 边缘损失函数的引入可能会使得非重要特征在超分辨率重建过程中得到加强，从而使得实际超分辨率重建的结构相似性有所降低，因此改进 SRGAN 网络计算得到的 SSIM 值比 ESPCN 网络的值要低。

此外本章为了验证将 BN 层改为 LN 层的影响，分别进行了保留原 BN 层，直接去掉 BN 层，将 BN 层改为 LN 层三种方案下，改进 SRGAN 网络进行×4 即 4 倍放大倍数超分辨率重建，在测试数据集上计算器平均 PSNR、SSIM 情况，并得到表 4-7 所示 BN 层改为 LN 层对试验效果。其中 PSNR、以及 SSIM 都是计算的测试集上的平均值结果。

中国知网 https://www.cnki.net

表 4-7　BN 层改为 LN 层对试验效果

	保留 BN 层		去掉 BN 层		将 BN 层换为 LN 层	
改进 SRGAN 网络	PSNR(dB)	SSIM	PSNR(dB)	SSIM	PSNR(dB)	SSIM
	25.18	0.8314	25.25	0.8327	**25.27**	**0.8332**

为了验证本章提出的在原始SRGAN网络中基于密集连接的SRGAN网络改进方法，与损失函数的改进的实际作用，本节进行了表 4-8 所示的本章各部分改进步骤消融实验，在测试集上对其进行×4 即 4 倍放大倍数超分辨重建，并将结果与目标 HR 图像进行比较，计算测试集的平均 PSNR、SSIM 情况。通过实验结果发现，基于密集连接的改进方法，以及基于损失函数的改进方法，都对 SRGAN 超分辨率重建的效果发挥着一定的作用，其中基于密集连接方式的改进方案对实验结果的提升效果最为明显。

表 4-8 本章各部分改进步骤消融实验

	平均 PSNR（dB）	平均 SSIM
原始 SRGAN 网络	24.89	0.8217
原始 SRGAN 网络+密集连接改进方法	25.21	0.8306
原始 SRGAN 网络+损失函数改进方法	24.98	0.8253
原始 SRGAN 网络+密集连接改进方法+损失函数改进	25.27	0.8332

（2）基于目标检测角度的评价

将第三章通过 CycleGAN 网络仿真生成的红外机场图像进行超分超分辨率重建，如图 4-11 所示经过超分辨率得到的机场飞机目标，其中图（a）表示 CycleGAN 仿真生成的红外机场图像，红色框为飞机目标，将图（a）中红色框定区域，通过图（b）双线性插值，以及图（c）改进 SRGAN 网络超分辨率重建，得到的高分辨率飞机目标，通过图（b）以及图（c）对比发现，双线性插值得到的图像，相对模糊，且边

中国知网 https://www.cnki.net

缘平滑，利用改进 SRGAN 超分得到的飞机目标，边缘更清晰一些，能更好的用于目标检测工作。

(a) (b) (c)

图 4-11 经过超分辨率得到的机场飞机目标

为了进一步验证对红外图像进行超分辨率重建工作，在目标检测中的作用，本章还在第三章利用 SSD 目标检测深度学习模型，进行红外机场目标检测基础上，进一步做对比实验。

具体的对比实验设置如下即：

① 直接添加 CycleGAN 网络生成红外数据到 SSD 目标检测网络模型的训练集中，同时不对 SSD 目标检测网络的原始基础数据集进行任何处理；

② 将生成的红外图像通过原始 SRGAN 网络 4 倍超分辨率重建后，再将其增加到 SSD 目标检测模型的训练数据集中，同时对 SSD 目标检测网络的原始基础数据集也使用原始 SRGAN 网络进行 4 倍超分辨率重建处理。

③ 将生成的红外图像通过本章改进 SRGAN 网络 4 倍超分辨率重建后，再将其增加到 SSD 目标检测模型的训练数据集中，同时对 SSD 目标检测网络的原始基础数据集也使用本章改进 SRGAN 网络进行 4 倍超分辨率重建处理。

本节仍然使用首先使用 900 张实际拍摄红外图像数据作为 SSD 目标检测网络的基础训练样本，而在 A 组直接添加改进 CycleGAN 生成的红外机场数据 900 张，同时不对 900 张实拍红外机场数据进行处理；B 组首先对改进 CycleGAN 生成的 900 张红外图像数据使用原始 SRGAN 网络进行超分辨率重建工作，同时对 900 张目标检测的基础数据集也使用原始 SRGAN 网络进行超分辨率重建工作；C 组首先对改进

中国知网 https://www.cnki.net

CycleGAN 生成的 900 张红外图像数据使用本章改进 SRGAN 网络进行超分辨率重建工作，同时对 900 张目标检测的基础数据集使用本章改进 SRGAN 网络进行超分辨率重建工作，得到表 4-9 以及图 4-12 所示实验结果 。

通过实验对比发现，在都不增加额外的数据到 SSD 目标检测网络的训练集中的情况下，只对 SSD 目标检测网络的基础 900 张实拍红外图像使用原始 SRGAN 网络，以及使用改进 SRGAN 网络进行超分辨率重建，红外机场目标检测效果要远好于不对红外图像进行超分辨率处理的效果，同时使用改进 SRGAN 网络对图像进行处理后的数据，添加到 SSD 目标检测网络的训练集中，得到的目标检测的效果也是最好的。同时在 SSD 网络的训练集中增加原始 SRGAN，以及改进 SRGAN 网络超分辨率重建的红外图像，比直接添加改进 CycleGAN 生成的红外图像到目标检测网络的训练集中的情况，其 SSD 网络的红外机场目标检测效果也会更好。同时通过上述实验发现，当 SSD 目标检测网络的训练数据非常少的情况下，对训练样本进行超分辨率处理，能够较大幅度提升 SSD 网络的检测效果，但是随着训练数据的增加，这种提升效果变得没有那么明显。

表 4-9　4 倍超分辨率重建对目标检测的影响

添加训练样本数量	直接添加改进 CycleGAN 生成红外机场(AP/%)	添加原始 SRGAN 超分辨重建红外机场(AP/%)	添加改进 SRGAN 网络超分辨率重建红外机场(AP/%)
0	75.6	76.5	77.1
200	76.1	77.3	78.1
400	76.6	78.1	78.9
600	77.3	79.0	79.6
800	78.1	79.7	80.1
1000	79.8	80.2	80.6
1200	79.9	80.6	80.8
1400	80.1	80.7	81.0
1600	80.1	80.9	81.1

中国知网 https://www.cnki.net

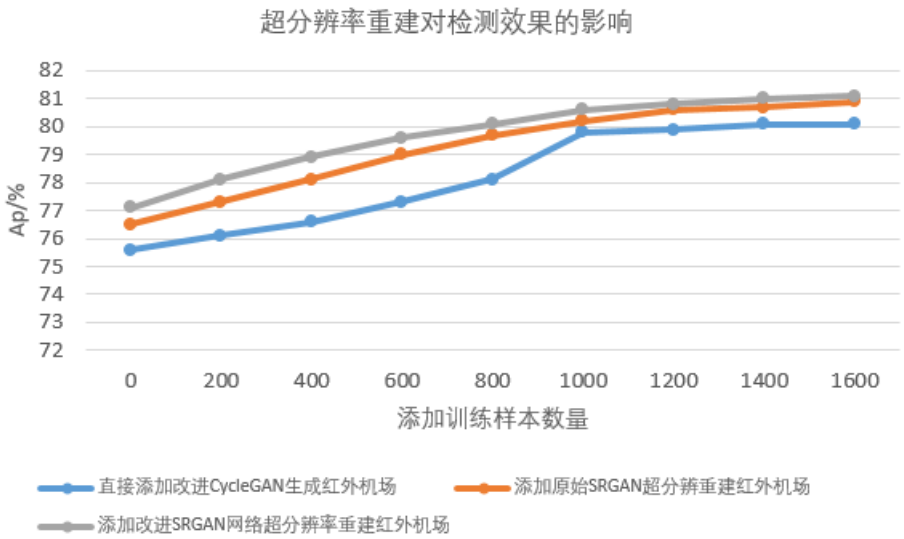

图 4-12　4 倍超分辨率重建对检测效果的影响

此外为了验证不同超分方法对图像进行不同放大倍数的情况下，对实际检测效果的影响，本节将对比 ESPCN 网络，原始 SRGAN 网络以及改进后 SRGAN 网络对上述红外机场图像进行 2 倍、4 倍不同放大倍数的超分辨率情况下，同样应用 SSD 网络作为目标检测网络。这里选用 2500 张低分辨率机场场景作为训练集，分别使用 ESPCN 网络，原始 SRGAN 网络以及改进后 SRGAN 网络分别对其进行 2 倍、4 倍超分辨率重建工作，将超分的结果作为 SSD 网络的训练集，并在测试集上得到表 4-10 所示不同方法 2 倍超分辨率重建检测结果，以及表 4-11 所示不同方法 4 倍超分辨率重建检测结果。通过对比表 4-10 以及表 4-11 结果发现使用 SRGAN 网络进行超分辨率重建的结果，能够比 ESPCN 网络超分的结果获得更好的检测效果，改进 SRGAN 网络能够比原始 SRGAN 网络获得够好的检测效果，同时通过实验发现，进行 4 倍超分辨率重建的目标检测结果能够比 2 倍超分辨率重建获得更好的检测效果。

表 4-10　不同方法 2 倍超分辨率重建检测结果

不同超分辨率重建方法	放大倍数	目标检测结果（AP/%）
ESPCN	×2	80.32
原始 SRGAN	×2	80.43
改进 SRGAN	×2	80.55

中国知网　https://www.cnki.net

表 4-11　不同方法 4 倍超分辨率重建检测结果

不同超分辨率重建方法	放大倍数	目标检测结果（AP/%）
ESPCN	×4	80.91
原始 SRGAN	×4	80.98
改进 SRGAN	×4	81.07

4.4 本章小结

本章为解决经过改进 CycleGAN 网络生成的红外图像以及实拍的红外图像中，存在部分图像质量不高、模糊，边缘轮廓不清晰，为了能够在较高分辨率成像条件下进行红外图像的目标检测识别任务，决定利用深度学习方法，对改进 CycleGAN 网络生成的部分低分辨率红外图像进行超分辨率重建工作，以期获得更高质量、信息更加丰富的红外图像。针对 SRGAN 生成器网络使用 ResNet 连接方式，对图像的底层信息利用不充分，本章借鉴 DenseNet 连接方式，对 SRGAN 网络改进，使生成器网络密集连接，同时通过实验发现在 SRGAN 网络进行超分辨率重建工作中，BN 层对网络的作用不大，本章使用 LN 层替换 BN 层结果。针对红外图像中边缘信息、纹理信息具有极为重要的意义，本章提出引入边缘梯度损失函数，加强图像边缘信息的关注度。最后为了验证本章红外图像超分辨率重建的效果，本文将改进后 SRGAN 超分效果，与原始 SRGAN 网络实验效果进行对比实验，同时为了验证红外图像超分辨率重建工作的意义，本章还通过实验分别使用未经超分数据、原始 SRGAN 超分数据以及改进 SRGAN 网络超分数据在红外目标检测效果上进行对比。综上本章对生成红外图像进行超分辨率重建，可以进一步提高红外图像质量，具有一定的研究意义与应用价值。

中国知网　https://www.cnki.net

5 总结与展望

5.1 论文工作总结

红外图像的仿真生成、以及对红外图像进行超分辨率重建工作具有重要的研究意义，目前的研究已经取得了一定的进展，但由于实际应用需求中对红外图像生成的真实性、可用性、多样性、迁移性都有着极高的要求，对该课题的研究任重而道远。本文主要工作如下：

（1）为了仿真生成可用性更高的红外图像，本文使用 CycleGAN 作为训练样本的深度学习模型，作为红外图像仿真的基本网络模型。针对利用 CycleGAN 网络进行红外图像生成过程存在生成过拟合而在部分仿真生成红外图像中出现整体模糊、局部错误映射问题，本文提出增加抑制器模块，将原有图像生成步骤由一步变为两步进行，即第一步进行生成，第二步进行反向验证，抑制生成过程中的过拟合失真现象的出现。

（2）针对 CycleGAN 网络一条路径生成的红外图像和另一条路径重建的红外图像理论上应该是一致的，但是实际生成过程中可能存在区别，而原始 CycleGAN 网络并未对其进行比较，本文在两条训练路径之间添加了计算生成路径和重建路径的损失函数 L_{sr}，将生成器生成的图像和另一条路径重建的结果的比较，从而加强网络循环一致性的约束，减少错误映射情况的出现，同时还能在一定程度上防止模式奔溃的出现，加强网络的稳定性。使用 L_{sr} 计算生成的红外图像与循环重建的红外图像，以及生成的可见光图像与循环重建的可见光图像的 L_1 距离。同时针对传统卷积神经网络，注意区域是有限，对红外图像的细节特征关注不够，容易遗漏或错误映射部分红外特征。本文引入注意力模块，通过将通道注意力、空间注意力结合进残差网络结构中，提高仿真生成红外图像的质量。

（3）针对经过 CycleGAN 仿真生成的红外图像，以及项目中实拍的红外图像，存在模糊，分辨率低等图像质量不高，为了能够在较高分辨、图像质量更好的红外成像条件下进行红外目标的检测识别任务。本文使用 SRGAN 网络结构对红外图像

中国知网 https://www.cnki.net

进行超分辨率重建工作，以期获得质量高、图像信息丰富的结果。针对 SRGAN 网络生成器模块使用 ResNet 链接方式，对 LR 图像进行超分工作时，对图像的底层信息利用不充分。本文提出使用 DenseNet 的密集链接方式，改进网络中生成器的连接结构，充分发挥每层信系的作用。针对红外图像中边缘信息、纹理信息具有极为重要的意义，本文在 SRGAN 损失函数中引入计算梯度损失函数项，加强对图像的边缘信息的约束性，同时此方法对减少图像生成中出现的棋盘格噪声也有一定的积极意义。

5.2 课题研究展望

本文虽然取得了一些阶段性的研究成果，但是仍然存在一些问题，需要进一步解决。在本文基础上，还可以从以下角度继续展开后续工作：

（1）由于本文在进行红外图像仿真过程中，红外数据严重不足，且该红外数据主要分布在正午 12:00 和晚间 7:00 两个时间段，且数据主体以正午时间，因此对夜晚红外图像的拟合效果较差。下一步可以在丰富训练数据集基础上，进行进一步工作，得到不同时间段红外图像的生成。此外由于本文在进行红外图像仿真中，训练样本以自然景观，建筑物为主，包含的车辆、飞机、坦克、人等信息较少，下一步可以在丰富训练样本种类情况下，进行图像中红外目标的生成工作。同时可以通过 StarGAN 网络进行红外图像的时段迁移方面的研究工作。

（2）本文所选用的 CycleGAN 网络，在进行红外图像仿真中，只能限定在将可见光图像转换为相应的红外图像，对于可见光图像中未出现的目标无法生成相应的红外图像，下一步可以更换网络模型结构，直接利用红外图像作为训练样本，利用样本中不同目标的信息要素，通过控制不同信息的自由组合方式，获取更加自由、多样的红外图像。同时在最新的图像生成网络中 BigGAN、BigBiGAN 具有更好的生成效果，但是由于此类模型对硬件资源需求过大，目前暂时不具备进行该实验工作硬件资源环境，下一步可以尝试进行网络模型压缩方式，利用该类型网络进行工作。

（3）本文在进行超分辨率重建工作中，由于所使用的红外图像本身质量并不高，因此网络最终的生成效果并不理想，下一步可以尝试收集质量更高的红外图像数据

中国知网 https://www.cnki.net

进行训练，也可以尝试通过直接使用高清的可见光图像数据进行训练，来对 LR 红外图像进行超分辨率重建工作。同时在超分辨率重建的实验中用于网络训练的数据集多为场景较为简单规则的图像，在进行较为复杂图像的超分实验时效果并不是很理想，后期可以搜集场景更为复杂且分辨率较高的红外图像进行实验训练工作。

综上所示，本文涉及的工作已在当前研究下取得一定的进步和提升，后续研究将在此基础上展开，进行进一步探究，以期获得更优的性能。

中国知网 https://www.cnki.net

致谢

逝者如斯夫！三年的硕士生涯终究是要结束了，尤其当毕业季遇到新冠肺炎这样一个特殊时期。回想第一次来到实验室仿佛还在昨天。回首过往的求学生涯，既有“为伊消得人憔悴”的艰难求索，亦有“蓦然回首”时的惊喜释然。对未知探索的过程竟是如此动人心魄，让人困惑、迷茫、煎熬、着迷、狂喜和留恋。终有所得便是不负初心，而今我要告别过往，开始人生的下一段旅程了。在此，要向那些给予我帮助和鼓励的人们表示最为衷心的感谢，是你们让我的求学生涯阳光明媚。

首先要衷心感谢我的导师王岳环教授。王老师为我创造了自由宽松的求学空间，传授了我做学问的方法和态度。在研究遇到瓶颈时，王老师的鼓舞和教导给予了我冲出难关的动力和勇气。王老师耐心细致的指导风格，平等开放的学术主张，谦虚谨慎、勤奋拼搏的治学态度和平实低调、真诚质朴的为人风采都深深地影响着我，使我终生受益。未来的人生旅途，漫长而不可知，老师传授我的获取知识与探索未知的方法，教导我的治学和为人的态度原则会一直帮助和鼓励我认真踏实、平静坚韧地面对未来工作和生活中的困难和挑战。

让我感到高兴和幸福的是，1008 实验室一直是一个团结友爱、朝气蓬勃、“逗逼”丛生的和谐大家庭。感谢实验室兄弟姐妹的陪伴，无论在生活上还是在学习上大家都给予了我最无私的帮助和关怀。感谢已毕业的颜小运、宋琼、张清顺、岳诺宁、杨岱逸、董良武等同门，我会永远记住你们，记住阳光明媚的 1008 东南角。还要感谢实验室的刘天宇、田昊东，我们交流项目，共同努力，相互鼓励的多年陪伴让人怀念。还要感谢实验室的柴宏伟、杜雅丽、戴开恒、张津浦、耿铭良等同学对我的关心和帮助。

还要感谢桑农、杨卫东、左峥嵘、黎云、颜露新、钟胜、胡静、邹腊梅等老师对我的帮助和鼓励。同时还要感激硕士 1701 班所有同学，与你们一起度过了研究生的快乐时光。

感谢我的父母，是你们给予我无私的爱，我的所有都是来自于你们无私的给予。感谢这些年来的理解和支持，养育之恩无以为报，原谅我的不擅表达，我深爱你们。

中国知网 https://www.cnki.net

参考文献

[1]Dozier J, Frew J. Rapid calculation of terrain parameters for radiation modeling from digital elevation data[J]. IEEE Transactions on Geoscience and Remote Sensing, 1990, 28(5): 963-969.

[2]Gerhart G, Martin G, Gonda T. Thermal image modeling[C]//Infrared Sensors and Sensor Fusion. International Society for Optics and Photonics, 1987, 782: 3-9.

[3]陈云. 红外多光谱图像仿真研究[D]. 武汉：华中科技大学图书馆, 2011.

[4] Biesel H, Rohlfing T. Real-time simulated forward looking infrared (FLIR) imagery for training[C]//Infrared image processing and enhancement. International Society for Optics and Photonics, 1987, 781: 71-80.

[5]薄郸. 面向目标识别的红外成像干扰仿真与分级方法研究[D]. 武汉：华中科技大学图书馆，2019.

[6]Ben-Yosef N, Rahat B, Feigin G. Simulation of IR images of natural backgrounds[J]. Applied Optics, 1983, 22(1): 190-193.

[7]Gilmore M A, Moorhead I R, Oxford D E, et al. CAMEO-SIM: a broadband scene generation system that is fit for purpose[C]//Targets and Backgrounds: Characterization and Representation V. International Society for Optics and Photonics, 1999, 3699: 217-228.

[8]张云，马崇宵，薛艳茹,等. 基于SE-Workbench-IR的红外视景仿真研究[J]. 弹箭与制导学报, 2010(04): 217-219.

[9]徐南荣，瞿荣贞. 飞行器的红外特性[J]. 红外与激光工程, 1999, 28(1): 8-14.

[10]周强，白廷柱，刘明奇等. 基于可见光图像的近红外场景仿真[J]. 红外技术, 2015, 37(1): 11-15.

[11]王章野. 地面目标的红外成像仿真及多光谱成像真实感融合研究[D]. 杭州：浙江大学图书馆, 2002.

[12]颜轶. 空中背景下目标与干扰红外场景仿真系统[D]. 武汉：华中科技大学图书馆，2015.

[13]张云，马崇宵，薛艳茹等. 基于SE-Workbench-IR 的红外视景仿真研究[J]. 弹箭

中国知网 https://www.cnki.net

与制导学报, 2010, 30(4): 211-213.

[14]张天序, 王飞, 赵广州. 多尺度多视点舰船目标红外视景仿真[J]. 华中科技大学学报: 自然科学版, 2007, 35(6): 1-3.

[15]Hertzmann A, Jacobs C E, Oliver N, et al. Image analogies[C]//Proceedings of the 28th annual conference on Computer graphics and interactive techniques. 2001: 327-340.

[16]Gatys L, Ecker A S, Bethge M. Texture synthesis using convolutional neural networks[C] Advances in neural information processing systems. 2015: 262-270.

[17]Gatys L A, Ecker A S, Bethge M, et al. A Neural Algorithm of Artistic Style[J]. Journal of Vision, 2016, 16(12): 326-326.

[18]Johnson J, Alahi A, Fei-Fei L. Perceptual losses for real-time style transfer and super-resolution[C]//European conference on computer vision. Springer, Cham, 2016: 694-711.

[19]Goodfellow I, Pouget-Abadie J, Mirza M, et al. Generative adversarial nets[C]//Advances in neural information processing systems. 2014: 2672-2680.

[20]Mirza M, Osindero S. Conditional generative adversarial nets[J]. arXiv preprint arXiv:2014, 1411.1784.

[21]Denton E L, Chintala S, Fergus R. Deep generative image models using a laplacian pyramid of adversarial networks[C]//Advances in neural information processing systems. 2015: 1486-1494.

[22]Radford A, Metz L, Chintala S. Unsupervised representation learning with deep convolutional generative adversarial networks[J]. arXiv preprint arXiv:2014, 1511.06434.

[23]Arjovsky M, Chintala S, Bottou L. Wasserstein gan[J]. arXiv preprint arXiv: 2017, 1701.07875.

[24]Isola P, Zhu J Y, Zhou T, et al. Image-to-image translation with conditional adversarial networks[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2017: 1125-1134.

[25]Zhu J Y, Park T, Isola P, et al. Unpaired image-to-image translation using cycle-consistent adversarial networks[C]//Proceedings of the IEEE international

中国知网 https://www.cnki.net

conference on computer vision. 2017: 2223-2232.

[26]Brock A, Donahue J, Simonyan K. Large scale gan training for high fidelity natural image synthesis[J]. arXiv preprint arXiv:2018, 1809.11096.

[27]Donahue J, Simonyan K. Large scale adversarial representation learning[C]//Advances in Neural Information Processing Systems. 2019: 10541-10551.

[28]许洪, 王向军. 基于可见光光谱图像的红外多光谱图像仿真生成[J]. 红外与激光工程,2009,28(2): 200-204.

[29]Huang Chaochao, Wu Xiaodi , Tian Wuqin. Infrared image simulation based on statistical learning theory[J]. International Journal of Infrared and Millimeter Waves, 2007, 28(12): 1143-1153.

[30]Zou L, Zhang T, Lv W, et al. Research on large-scale scene infrared simulation based on image classification[C]//2011 International Workshop on Multi-Platform/Multi-Sensor Remote Sensing and Mapping. IEEE, 2011: 1-6.

[31]吴晓迪, 黄超超, 路远. 基于 BP 神经网络的路面红外图像仿真[J]. 红外技术, 2007, 29(7): 409-412.

[32]谢江荣, 李范鸣, 卫红等. 基于生成对抗式神经网络的红外目标仿真方法[J]. 光学学报, 2019,039（003）:142-148.

[33]Harris J L. Diffraction and resolving power[J]. JOSA, 1964, 54(7): 931-936 .

[34]Tsai R Y, Huang T S. Multiframe image restoration and registration[J]. Advances in computer vision and Image Processing, 1984,1(2):317-339.

[35]Rhee S, Kang M G. Discrete cosine transform based regularized high-resolution image reconstruction algorithm[J]. Optical Engineering, 1999, 38(8): 1348-1356.

[36]Kim S P, Bose N K, Valenzuela H M. Recursive reconstruction of high resolution image from noisy undersampled multiframes[J]. IEEE Transactions on Acoustics, Speech, and Signal Processing, 1990, 38(6): 1013-1027.

[37]Kim S P, Su W Y. Recursive high-resolution reconstruction of blurred multiframe images[J]. IEEE Transactions on Image Processing, 1993, 2(4): 534-539.

[38]Ur H, Gross D. Improved resolution from subpixel shifted pictures[J].

中国知网 https://www.cnki.net

CVGIP: Graphical Models and Image Processing, 1992, 54(2):181-186.

[39]Shah N R, Zakhor A. Resolution enhancement of color video sequences[J]. IEEE transactions on Image Processing, 1999, 8(6): 879-885.

[40]Stark H, Oskoui P. High-resolution image recovery from image-plane arrays, using convex projections[J]. JOSA A, 1989, 6(11): 1715-1726.

[41]Alam M S, Bognar J G, Hardie R C, et al. Infrared image registration and high-resolution reconstruction using multiple translationally shifted aliased video frames[J]. IEEE Transactions on instrumentation and measurement, 2000, 49(5): 915-923.

[42]Irani M, Peleg S. Super resolution from image sequences[C]//Proceedings. 10th International Conference on Pattern Recognition. IEEE, 1990, 2: 115-120.

[43]Farsiu S, Robinson D, Elad M, et al. Advances and challenges in super‐resolution[J]. International Journal of Imaging Systems and Technology, 2004, 14(2): 47-57.

[44]Freeman W T, Jones T R, Pasztor E C. Example-based super-resolution[J]. IEEE Computer graphics and Applications, 2002, 22(2): 56-65.

[45]Elad M, Aharon M. Image denoising via sparse and redundant representations over learned dictionaries[J]. IEEE Transactions on Image processing, 2006, 15(12): 3736-3745.

[46]Chang H, Yeung D Y, Xiong Y. Super-resolution through neighbor embedding[C]//Proceedings of the 2004 IEEE Computer Society Conference on Computer Vision and Pattern Recognition, 2004, I-I.

[47]Dong C, Loy C C, He K, et al. Learning a deep convolutional network for image super-resolution[C]//European conference on computer vision. Springer, Cham, 2014: 184-199.

[48]Dong C, Loy C C, Tang X. Accelerating the super-resolution convolutional neural network[C]//European conference on computer vision. Springer, Cham, 2016: 391-407.

[49]Žbontar J, LeCun Y. Stereo matching by training a convolutional neural network to compare image patches[J]. The journal of machine learning research, 2016, 17(1): 2287-2318.

中国知网 https://www.cnki.net

[50]Shi W, Caballero J, Huszár F, et al. Real-time single image and video super-resolution using an efficient sub-pixel convolutional neural network[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2016: 1874-1883.

[51]Ledig C, Theis L, Huszár F, et al. Photo-realistic single image super-resolution using a generative adversarial network[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2017: 4681-4690.

[52]Huang G, Liu Z, Van Der Maten L, et al. Densely connected convolutional networks[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2017: 4700-4708.

[53]Ronneberger O, Fischer P, Brox T, et al. U-Net: Convolutional Networks for Biomedical Image Segmentation[C]. medical image computing and computer assisted intervention, 2015: 234-241.

[54]朱军. 基于StableGAN的异谱段红外图像变换方法研究[D]. 武汉：华中科技大学图书馆, 2018.

[55]He K, Zhang X, Ren S, et al. Deep residual learning for image recognition[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2016: 770-778.

[56]Woo S, Park J, Lee J Y, et al. Cbam: Convolutional block attention module[C]//Proceedings of the European Conference on Computer Vision (ECCV). 2018: 3-19.

[57]Liu W, Anguelov D, Erhan D, et al. Ssd: Single shot multibox detector[C]//European conference on computer vision. 2016: 21-37.

[58]Lim B, Son S, Kim H, et al. Enhanced deep residual networks for single image super-resolution[C]//Proceedings of the IEEE conference on computer vision and pattern recognition workshops. 2017: 136-144.

[59]Ioffe S, Szegedy C. Batch normalization: Accelerating deep network training by reducing internal covariate shift[J]. arXiv preprint arXiv: 2015, 1502.03167.

中国知网 https://www.cnki.net

附录 1　攻读学位期间取得的成果

[1]第一作者**(导师)**，**第二作者**，第三作者，An infrared turbulence infrared imaging simulation based on improved Generative Adversarial Networks. SPIE, MIPPR 2019（EI 收录）

[2]第一作者，第二作者，**第三作者**，第四作者，Combined infrared simulation and pix2pix model for underground target detection. SPIE, MIPPR 2019（EI 收录）

中国知网　https://www.cnki.net